

หัวข้อโครงการวิศวกรรมคอมพิวเตอร์
หลักสูตรวิศวกรรมศาสตรบัณฑิต สาขาวิศวกรรมคอมพิวเตอร์
ปีการศึกษา 2568

ชื่อโครงการ

A Performance Enhancement Platform for Learning Calculus
แพลตฟอร์มพัฒนาประสิทธิภาพการเรียนรู้แคลคูลัส

สมาชิก

- 1) นางสาวปณิธิ รุ่งประเสริฐ รหัสนักศึกษา 65070501038
- 2) นายพิชญุตม์ แจ่มพงษ์ รหัสนักศึกษา 65070501079

อาจารย์ที่ปรึกษา

ทศชัย นันทะพัชร
(ดร.ทวิชัย นันทวิสุทธิวงศ์)

บทที่ 1

1.1 ที่มาและความสำคัญของปัญหา

การจัดการเรียนการสอนในปัจจุบันยังคงเผชิญกับข้อจำกัดหลายประการ โดยเฉพาะในรายวิชาที่มีความซับซ้อนสูงอย่างคณิตศาสตร์ระดับมัธยมศึกษาตอนปลาย ซึ่งปัญหาที่พบได้บ่อย ได้แก่ ภาระของครูผู้สอนในการดูแลนักเรียนจำนวนมากซึ่งทำให้ไม่สามารถติดตามและวิเคราะห์ความเข้าใจรายบุคคลได้อย่างใกล้ชิด การที่ผู้เรียนไม่สามารถประเมินระดับความเข้าใจและพัฒนาการของตนเองได้อย่างชัดเจนเนื่องจากขาดข้อมูลสะท้อนกลับที่เพียงพอ และข้อสอบหรือแบบฝึกหัดที่ใช้อยู่ในปัจจุบันซึ่งไม่สามารถตอบสนองต่อความแตกต่างระหว่างผู้เรียนได้อย่างเหมาะสม ทั้งในด้านเนื้อหาและระดับความยาก โดยเฉพาะในหัวข้อแคลคูลัสที่มักถูกมองว่าเป็นอุปสรรคสำคัญต่อการเรียนรู้

ประเด็นแรกคือ ภาระของครูผู้สอนที่ต้องดูแลนักเรียนจำนวนมากในเวลาเดียวกัน ส่งผลให้ไม่สามารถวิเคราะห์จุดแข็งและจุดอ่อนของผู้เรียนแต่ละคนได้อย่างละเอียด การสอนจึงขาดความยืดหยุ่นในการปรับให้เหมาะสมกับผู้เรียนรายบุคคล ส่งผลให้ผู้เรียนบางส่วนเรียนต่อไปโดยที่ยังไม่เข้าใจเนื้อหาอย่างแท้จริง และไม่สามารถเชื่อมโยงแนวคิดที่เรียนไปประยุกต์ใช้ในสถานการณ์ใหม่ได้

ในด้านของผู้เรียนเอง มักไม่สามารถประเมินระดับความเข้าใจของตนเองได้อย่างแม่นยำ เนื่องจากขาดข้อมูลสะท้อนกลับที่มีคุณภาพ เช่น ผลการสอบที่บอกเพียงว่าคำตอบ ถูก หรือ ผิด โดยไม่มีคำอธิบายเพิ่มเติม การขาดกลไกดังกล่าวทำให้ผู้เรียนไม่สามารถมองเห็นจุดแข็งและจุดอ่อนของตนเองอย่างชัดเจน ไม่รู้ว่าควรปรับปรุงในส่วนใด และไม่สามารถกำหนดเป้าหมายการเรียนรู้ที่เหมาะสมได้ นอกจากนี้ยังส่งผลโดยตรงต่อแรงจูงใจ เนื่องจากผู้เรียนไม่สามารถมองเห็นพัฒนาการของตนเองได้อย่างเป็นรูปธรรม

อีกประเด็นหนึ่งคือแบบฝึกหัดและข้อสอบที่ใช้อยู่ในปัจจุบันยังไม่สามารถตอบโจทย์ความต้องการของผู้เรียนทุกกลุ่มได้อย่างแท้จริง ข้อสอบบางชุดอาจง่ายเกินไปจนไม่ก่อให้เกิดความท้าทาย ขณะที่บางชุดกลับยากเกินไปจนผู้เรียนไม่สามารถเรียนรู้ได้อย่างมีประสิทธิภาพ อีกทั้งยังมีข้อจำกัดในด้านจำนวนและความหลากหลายของโจทย์ เช่น ผู้เรียนบางคนต้องการฝึกโจทย์ลักษณะเฉพาะ แต่กลับพบว่าข้อสอบในลักษณะนั้นไม่เพียงพอ ส่งผลให้ไม่สามารถฝึกฝนได้อย่างต่อเนื่อง

จากปัญหาที่กล่าวมาทั้งหมด ผู้จัดทำจึงมีแนวคิดในการพัฒนาแพลตฟอร์มเพื่อช่วยให้การเรียนรู้คณิตศาสตร์มีประสิทธิภาพและตอบโจทย์ผู้เรียนมากยิ่งขึ้น โดยเฉพาะในหัวข้อแคลคูลัสเบื้องต้นซึ่งเป็นเนื้อหาที่นักเรียนจำนวนมากพบว่ายากต่อความเข้าใจ แพลตฟอร์มดังกล่าวจะมีระบบสร้างข้อสอบขึ้นมาใหม่จากคลังที่มีอยู่ เพื่อให้นักเรียนสามารถฝึกทำข้อสอบที่เหมาะสมกับความสามารถของตนเองได้อย่างต่อเนื่อง นอกจากนี้ยังมีระบบวิเคราะห์ผลการทำข้อสอบซึ่งจะช่วยสะท้อนให้ผู้เรียนเห็นว่าตนเองมีความเข้าใจในประเด็นใดบ้าง จุดใดที่ยังเป็นข้อผิดพลาด และควรปรับปรุงหรือฝึกฝนเพิ่มเติมในหัวข้อใด เพื่อแก้ปัญหาที่ผู้เรียนไม่สามารถประเมินตนเองได้อย่างชัดเจน พร้อมกันนี้แพลตฟอร์มยังมีแดชบอร์ดสรุปพัฒนาการในรูปแบบที่เข้าใจง่าย เพื่อให้ผู้เรียนสามารถติดตามความก้าวหน้าของตนเองได้อย่างต่อเนื่อง และเห็นทิศทางการพัฒนาของตนเองอย่างเป็นรูปธรรม แพลตฟอร์มที่พัฒนาขึ้นจึงถือเป็นเครื่องมือที่จะช่วยตอบโจทย์ทั้งการติดตามรายบุคคล การสร้างข้อสอบที่เหมาะสมต่อการฝึกฝน และการทำให้ผู้เรียนเข้าใจตนเองมากขึ้น

1.2 วัตถุประสงค์

1. เพื่อสร้างระบบสร้างข้อสอบใหม่จากคลังข้อสอบที่มีอยู่ และสามารถกำหนดระดับความยากได้อย่างเหมาะสมกับผู้เรียน
2. เพื่อพัฒนาระบบวิเคราะห์ผลการทำข้อสอบที่สามารถสะท้อนจุดแข็งและจุดอ่อนของผู้เรียนได้อย่างชัดเจน
3. เพื่อสร้างแดชบอร์ดที่น่าเสนอพัฒนาการของผู้เรียนในรูปแบบที่เข้าใจง่ายและติดตามได้ต่อเนื่อง

1.3 ขอบเขตการดำเนินงาน

โครงการนี้มุ่งเน้นการพัฒนาระบบต้นแบบ (Prototype System) สำหรับการสร้างข้อสอบและการวิเคราะห์ผลการเรียนรู้ของผู้เรียน โดยมีรายละเอียดขอบเขตดังนี้

1. กลุ่มเป้าหมาย

ระบบนี้ถูกออกแบบมาเพื่อสนับสนุนผู้เรียนในระดับมัธยมศึกษาตอนปลาย โดยมุ่งเน้นเฉพาะรายวิชาคณิตศาสตร์ในหัวข้อแคลคูลัสเบื้องต้น การทำงานของระบบมุ่งเน้นการติดตามพัฒนาการของผู้เรียนในลักษณะรายบุคคล ผู้เรียนแต่ละคนสามารถเข้าถึงและดูผลลัพธ์การเรียนรู้ของตนเองได้เท่านั้น โดยระบบจะไม่ครอบคลุมการใช้งานสำหรับครูผู้สอนหรือการติดตามผลของผู้อื่น

2. เนื้อหาที่ครอบคลุม

ขอบเขตของโจทย์ที่ใช้ในระบบจะครอบคลุมหัวข้อสำคัญของแคลคูลัสเบื้องต้น ได้แก่

- ลิมิต (Limit)
- อนุพันธ์ (Derivative)
- ปริพันธ์ (Integral)
- การประยุกต์แคลคูลัส (Optimization, Motion, การหาพื้นที่และปริมาตร)

ทั้งนี้ โครงการไม่ครอบคลุมเนื้อหาคณิตศาสตร์ในสาขาอื่น เช่น ความน่าจะเป็น สถิติ หรือเรขาคณิต

3. การสร้างระบบ

ระบบถูกออกแบบให้สามารถใช้งานได้ผ่านเว็บเบราว์เซอร์ทั่วไป ซึ่งรองรับทั้งอุปกรณ์คอมพิวเตอร์ตั้งโต๊ะ แท็บเล็ต และมือถือ เพื่อความสะดวกในการเข้าถึงของผู้ใช้ แบ่งเป็น 3 ส่วนหลัก ได้แก่

- ส่วนติดต่อผู้ใช้ : นักเรียนสามารถทำข้อสอบและดูผลการวิเคราะห์
- ส่วนประมวลผล : ใช้สำหรับสุ่มโจทย์ วิเคราะห์ผลการทำข้อสอบ และสรุปพัฒนาการ
- ฐานข้อมูล : ใช้สำหรับจัดเก็บโจทย์และผลการทำข้อสอบของผู้เรียนรายบุคคล โดยในระยะเริ่มต้นจะมีการจัดเก็บข้อสอบไว้ในคลังจำนวนประมาณ 100 ชุด เพื่อรองรับการสร้างและสุ่มข้อสอบสำหรับการฝึกฝน

4. ระยะเวลาดำเนินงาน

- ภาคการศึกษาที่ 1: ศึกษา ออกแบบระบบ และพัฒนา Prototype
- ภาคการศึกษาที่ 2: พัฒนาระบบจริง ทดสอบการใช้งาน ปรับปรุง และนำเสนอผลลัพธ์โครงการ

1.4 แผนการดำเนินงาน

ภาคการศึกษาที่ 1

1. ศึกษาหัวข้อโครงการ
 - a. ศึกษาแนวคิดเกี่ยวกับ Personalized Learning
 - b. ศึกษาการประยุกต์ใช้ AI/ML ในด้าน Education Technology
 - c. ศึกษาหลักสูตรคณิตศาสตร์ (Calculus) ระดับมัธยมปลาย
2. จัดทำเอกสารแนวคิดโครงการ
 - a. ระบุปัญหา
 - b. กำหนดวัตถุประสงค์
 - c. ขอบเขตการดำเนินงาน
3. ทบทวนวรรณกรรม
 - a. ศึกษาระบบ Personalized Learning ที่มีการพัฒนาอยู่แล้ว
 - b. ศึกษาการใช้ NLP/LLM สำหรับการสร้างโจทย์อัตโนมัติ
 - c. ศึกษาเทคนิค ML/Clustering สำหรับการวิเคราะห์ผู้เรียน
 - d. ศึกษาการพัฒนา Dashboard สำหรับการติดตามการเรียนรู้
 - e. ศึกษาเทคโนโลยีในการพัฒนา Web application
4. จัดทำข้อเสนอโครงการฉบับละเอียด
 - a. ออกแบบสถาปัตยกรรมระบบ
 - b. เลือกเทคโนโลยีที่เหมาะสม
 - c. ออกแบบ Dataset
5. เตรียมการนำเสนอโครงการ
 - a. จัดทำสไลด์นำเสนอและตัวอย่างการทำงาน
6. นำเสนอโครงการภาคการศึกษาที่ 1
7. จัดทำรายงานสรุปผลการดำเนินงานประจำภาค
8. เริ่มต้นการพัฒนาทางเทคนิค
 - a. ออกแบบและสร้าง Dataset แคลคูลัสเบื้องต้น
 - b. พัฒนา Script สำหรับ Auto Tagging ด้วย Pandas
 - c. กำหนดเกณฑ์การแบ่งระดับความยากของโจทย์
 - d. พัฒนา API เบื้องต้น สำหรับเรียกใช้งานโจทย์
 - e. สร้าง Prototype UI สำหรับการแสดงข้อสอบ

ภาคการศึกษาที่ 2

1. พัฒนาระบบสร้างข้อสอบอัตโนมัติ
 - a. พัฒนา logic การสุ่มโจทย์/ชุด Quiz ตามระดับความยาก
2. พัฒนาระบบวิเคราะห์ความสามารถของผู้เรียน
 - a. พัฒนาโมเดล Machine Learning
 - b. ประยุกต์ใช้วิธีการเรียนรู้ของเครื่องด้านการจัดกลุ่ม เพื่อค้นหารูปแบบและแนวโน้มของผู้เรียน
 - c. สร้าง Script วิเคราะห์ข้อมูลเชิงสถิติ
3. พัฒนา Dashboard แสดงพัฒนาการผู้เรียน
 - a. พัฒนา Backend สำหรับ Query และ Preprocessing ข้อมูล
 - b. พัฒนา Visualization
 - c. เพิ่มฟังก์ชัน Filtering สำหรับการดูผลย้อนหลัง
4. ทดสอบระบบ
 - a. ทำ Unit Testing
 - b. Integration Testing
 - c. Usability Testing กับกลุ่มผู้ใช้งานจริง (นักเรียน/นักศึกษา)
5. ปรับปรุงและพัฒนาระบบ
 - a. เก็บ Feedback และปรับปรุง UI/UX
 - b. ขยาย Dataset ด้วยโจทย์เพิ่มเติม
6. สรุปผลและจัดทำรายงาน
 - a. วิเคราะห์ผลสำเร็จเมื่อเทียบกับวัตถุประสงค์โครงการ
 - b. ระบุข้อจำกัดของระบบ
 - c. เสนอแนวทางการพัฒนาในอนาคต
7. เตรียมการนำเสนอผลงาน
 - a. จัดทำสไลด์และ Demo ของระบบจริง
8. นำเสนอโครงงานภาคการศึกษาที่ 2

1.5 ตารางการดำเนินงาน

[illegible]

รายละเอียดงาน	สิงหาคม				กันยายน				ตุลาคม				พฤศจิกายน				ธันวาคม				มกราคม				กุมภาพันธ์				มีนาคม				เมษายน				พฤษภาคม				ผู้รับผิดชอบ
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	
11. พัฒนาทางเทคนิค (Phase 2 – Feature Development)																																									ทุกคน
11.1 พัฒนาฟีเจอร์การสร้างข้อสอบ																																									พิชญุตม์
11.2 พัฒนาฟีเจอร์วิเคราะห์ผลลัพธ์																																									ทุกคน
11.3 พัฒนาฟีเจอร์ Dashboard แสดงพัฒนาการ																																									ปณิธิ
12. ทดสอบระบบ																																									ทุกคน
12.1 ทดสอบการทำงานของแต่ละฟีเจอร์																																									ปณิธิ
12.2 ทดสอบการทำงานร่วมกันของระบบ																																									พิชญุตม์
12.3 ทดลองใช้งานจริงกับผู้เรียนกลุ่มเล็ก																																									ทุกคน
13. ปรับปรุงและพัฒนาระบบ																																									ทุกคน
13.1 แก้ไขข้อบกพร่องจากการทดสอบ																																									ทุกคน
13.2 ปรับประสิทธิภาพระบบ																																									ทุกคน
13.3 เตรียมระบบสำหรับการใช้งานจริง																																									ทุกคน
14. เตรียมการนำเสนอผลงานภาคการศึกษาที่ 2																																									ทุกคน
14.1 สรุปผลและจัดทำรายงานฉบับสมบูรณ์																																									ทุกคน
14.2 จัดทำสไลด์และ Demo ของระบบจริง																																									ทุกคน
14.3 ข้อมการนำเสนอ																																									ทุกคน
15. นำเสนอโครงงานภาคการศึกษาที่ 2																																									ทุกคน

1.6 ผลการดำเนินการ

ผลการดำเนินงานในภาคการศึกษาที่ 1

- เอกสารแนวคิดโครงงาน
- ข้อเสนอโครงงานแบบละเอียด
- ข้อเสนอโครงงาน
- Prototype UI
- Presentation เพื่อนำเสนอ
- รายงานประจำภาคการศึกษาที่ 1

ผลการดำเนินงานในภาคการศึกษาที่ 2

- Demo application
- Presentation เพื่อนำเสนอ
- รายงานประจำภาคการศึกษาที่ 2

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

ในบทนี้จะเป็นการนำเสนอกรอบแนวคิดและองค์ความรู้ที่เกี่ยวข้องกับการพัฒนาแพลตฟอร์ม โดยประกอบด้วยการทบทวนทฤษฎีที่เกี่ยวข้องซึ่งเป็นรากฐานทางวิชาการที่ใช้ในการกำหนดแนวทางการออกแบบและพัฒนา เช่น แนวคิดด้านการเรียนรู้ การวิเคราะห์ข้อมูล และการประยุกต์ใช้ปัญญาประดิษฐ์ และการนำเสนองานวิจัยที่เกี่ยวข้อง โดยรวบรวมและสังเคราะห์ผลงานวิชาการและระบบที่มีมาก่อนหน้า เพื่อนำมาเปรียบเทียบ วิเคราะห์ และแสดงให้เห็นถึงความก้าวหน้า เนื้อหาในบทนี้จึงมีความสำคัญอย่างยิ่งในการวางรากฐานเชิงทฤษฎีและเชิงประจักษ์ เพื่อให้การดำเนินงานวิจัยในบทต่อไปมีความถูกต้อง สอดคล้อง และมีทิศทางที่ชัดเจน

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 ทฤษฎีด้านการเรียนรู้และการศึกษา

2.1.1.1 Personalized Learning (การเรียนรู้รายบุคคล)

Personalized Learning คือแนวคิดด้านการเรียนรู้ที่เน้นการปรับเปลี่ยนเนื้อหา วิธีการ และความเร็วในการเรียนให้เหมาะสมกับผู้เรียนแต่ละคน โดยคำนึงถึงพื้นฐาน ความสามารถ และความสนใจที่แตกต่างกัน แนวคิดนี้ได้รับการยอมรับอย่างกว้างขวางว่าเป็นการปฏิวัติการเรียนรู้ในยุคดิจิทัล เนื่องจากช่วยลดช่องว่างระหว่างผู้เรียนที่มีระดับความเข้าใจไม่เท่ากัน การปรับการเรียนรู้ให้รายบุคคลทำให้ผู้เรียนมีโอกาสเรียนในรูปแบบที่สอดคล้องกับความถนัดของตนเองมากขึ้น

กระบวนการของ Personalized Learning มักเริ่มจากการประเมินความสามารถเบื้องต้นของผู้เรียน ไม่ว่าจะเป็นการทดสอบก่อนเรียนหรือการเก็บข้อมูลพฤติกรรมการเรียน จากนั้นจึงนำข้อมูลมาปรับเนื้อหาและโจทย์ให้เหมาะกับจุดแข็งและจุดอ่อนของผู้เรียน การเรียนการสอนจะมีการสะท้อนผลอย่างต่อเนื่อง เช่น การให้ Feedback รายบุคคลหรือการวิเคราะห์ผ่านระบบดิจิทัล ข้อมูลเหล่านี้จะถูกนำไปปรับปรุงการสอนในรอบถัดไป ทำให้กระบวนการเกิดการเรียนรู้เชิงพลวัต หรือ Iterative Learning Cycle ที่ช่วยพัฒนาผู้เรียนอย่างต่อเนื่อง

ความจำเป็นของ Personalized Learning มาจากความจริงที่ว่าผู้เรียนในห้องเรียนเดียวกันมักมีพื้นฐาน ความเข้าใจ และสไตล์การเรียนรู้ที่แตกต่างกัน หากใช้การสอนในรูปแบบเดียวกันกับผู้เรียนทุกคนอาจทำให้บางคนไม่สามารถตามเนื้อหาได้ทัน ในขณะที่บางคนรู้สึกว่ายากเกินไป ส่งผลให้ขาดแรงจูงใจ แนวคิด Personalized Learning จึงเข้ามาแก้ปัญหานี้ โดยทำให้ผู้เรียนทุกระดับสามารถได้รับประสบการณ์การเรียนรู้ที่เหมาะสมและท้าทายตามศักยภาพของตนเอง งานวิจัยของ Walkington ยังแสดงให้เห็นว่าการเชื่อมโยงจิตวิทยาคณิตศาสตร์กับความสนใจของผู้เรียนสามารถเพิ่มแรงจูงใจและความเข้าใจได้อย่างชัดเจน

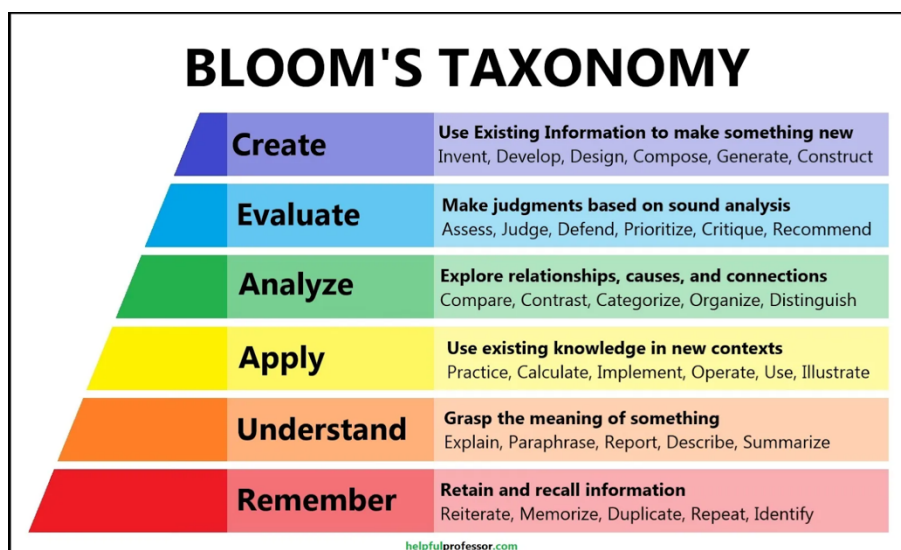
ในเชิงการประยุกต์ Personalized Learning มักถูกใช้ในระบบ Adaptive Learning ที่ใช้ Machine Learning หรือ AI วิเคราะห์พฤติกรรมเรียนและสร้างเส้นทางการเรียนรู้เฉพาะบุคคล ตัวอย่างที่ชัดเจนคือแพลตฟอร์มออนไลน์อย่าง Khan Academy ซึ่งปรับข้อสอบและบทเรียนให้ตรงกับระดับของผู้เรียน รวมถึง

Coursera และ EdX ที่ใช้ข้อมูลการเรียนรู้ของผู้ใช้ในการแนะนำคอร์สที่เหมาะสม นอกจากนี้ งานวิจัยเชิงประจักษ์หลายชิ้นยังพบว่าการใช้ Personalized Learning ไม่เพียงเพิ่มผลสัมฤทธิ์ทางการเรียน แต่ยังช่วยสร้างแรงจูงใจและทำให้ผู้เรียนมีความเชื่อมั่นในตนเองมากขึ้น

2.1.1.2 Bloom's Taxonomy of Educational Objectives

Bloom's Taxonomy of Educational Objectives เป็นกรอบแนวคิดด้านการศึกษา ที่พัฒนาโดย Benjamin Bloom และ คณะในปี ค.ศ. 1956 โดยมีจุดประสงค์เพื่อจำแนกระดับการเรียนรู้ของผู้เรียนในเชิงพุทธิพิสัย หรือ Cognitive Domain ตั้งแต่ระดับพื้นฐานไปจนถึงขั้นสูงสุด ต่อมา Anderson และ Krathwohl ได้ปรับปรุงกรอบแนวคิดดังกล่าวให้ทันสมัยและสอดคล้องกับการเรียนรู้ในศตวรรษที่ 21 โดยเฉพาะการเน้นทักษะการคิดเชิงวิเคราะห์และการสร้างสรรค์ กรอบนี้ได้รับความนิยมอย่างแพร่หลาย เนื่องจากสามารถอธิบายลำดับพัฒนาการทางการเรียนรู้ได้อย่างชัดเจนและเป็นระบบ ซึ่งกรอบแนวคิด Bloom's Taxonomy แบ่งการเรียนรู้ออกเป็น 6 ชั้นตามลำดับดังนี้

1. Remember (การจำ) : ระลึกหรือท่องจำความรู้ ข้อเท็จจริง หรือสูตรพื้นฐาน
2. Understand (การเข้าใจ) : อธิบายความหมาย แปลความ และสรุปใจความสำคัญได้
3. Apply (การประยุกต์ใช้) : นำความรู้ไปใช้แก้ปัญหาในสถานการณ์ใหม่
4. Analyze (การวิเคราะห์) : แยกองค์ประกอบ ความสัมพันธ์ หรือโครงสร้างของข้อมูล
5. Evaluate (การประเมินค่า) : ตัดสินใจหรือให้เหตุผลโดยอ้างอิงหลักเกณฑ์
6. Create (การสร้างสรรค์) : ผสมผสานความรู้เพื่อสร้างสิ่งใหม่หรือแนวทางแก้ปัญหาที่ไม่ซ้ำเดิม



ที่มา : <https://tigerlearn.fhsu.edu/the-revised-blooms-taxonomy-as-a-framework-for-writing-learning-objectives/>

ซึ่งกระบวนการเรียนรู้ตาม Bloom's Taxonomy เป็นลำดับขั้นที่สะท้อนถึงการพัฒนาความคิดของผู้เรียนจากระดับต้นไปสู่ระดับลึกมากขึ้น กล่าวคือ เริ่มจาก การจำ ข้อมูลพื้นฐาน การเข้าใจ เนื้อหา การนำไปใช้ การวิเคราะห์ อย่างมีเหตุผล การประเมินค่า เพื่อตัดสินใจ และสูงสุดคือ การสร้างสรรค์ แนวทาง

ใหม่ ตัวอย่างเช่น ในการเรียนวิชาคณิตศาสตร์ ผู้เรียนอาจเริ่มจากการจำสูตรอนุพันธ์ (Remember) ต่อด้วยการเข้าใจความหมายเชิงเรขาคณิตของอนุพันธ์ (Understand) จากนั้นนำไปหาค่าของโจทย์ใหม่ (Apply) วิเคราะห์การเปลี่ยนแปลงของกราฟ (Analyze) ประเมินวิธีแก้ของเพื่อน (Evaluate) และสุดท้ายคือสร้างโจทย์หรือสถานการณ์ใหม่ที่ใช้อนุพันธ์ในการแก้ปัญหา (Create)

นอกจากนี้การนำ Bloom's Taxonomy มาประยุกต์ใช้กับการพัฒนาแพลตฟอร์มข้อสอบคณิตศาสตร์สามารถช่วยแก้ปัญหาที่พบในระบบการศึกษา เช่น การที่นักเรียนไม่รู้ว่าตนเองอยู่ในระดับความเข้าใจใด หรือโจทย์ที่ได้รับไม่เหมาะสมกับศักยภาพของตน โดยสามารถออกแบบข้อสอบตามระดับการคิด เช่น

- Remember : ถามสูตรอนุพันธ์ของฟังก์ชันพื้นฐาน
- Understand : ให้ผู้เรียนอธิบายความหมายของอนุพันธ์ในเชิงความชันของกราฟ
- Apply : หาค่าอนุพันธ์ของโจทย์ใหม่ที่ไม่เคยเจอมาก่อน
- Analyze : วิเคราะห์การเปลี่ยนแปลงของฟังก์ชันจากค่าอนุพันธ์อันดับหนึ่งและสอง
- Evaluate : เปรียบเทียบวิธีแก้โจทย์จากนักเรียนสองคน พร้อมอธิบายเหตุผล
- Create : ออกแบบโจทย์คณิตศาสตร์ที่ใช้อนุพันธ์ในการแก้ปัญหจริง

การประยุกต์ใช้ในลักษณะนี้ไม่เพียงช่วยสร้างโจทย์ที่เหมาะสมกับผู้เรียนแต่ละระดับ แต่ยังทำให้ผู้เรียนเห็นพัฒนาการของตนเองอย่างเป็นรูปธรรม ซึ่งสอดคล้องกับเป้าหมายของโครงการในการพัฒนาแพลตฟอร์มเพื่อเสริมสร้างการเรียนรู้คณิตศาสตร์อย่างมีประสิทธิภาพ

2.1.1.3 Knowledge Tracing

Knowledge Tracing (KT) คือ กระบวนการติดตามและประเมินความรู้ ความเข้าใจ และทักษะของผู้เรียนตามช่วงเวลา โดยอาศัยข้อมูลจากพฤติกรรมคำตอบคำถามหรือการทำแบบฝึกหัด แนวคิดนี้มุ่งเน้นการสร้างแบบจำลองสถานะความรู้ของผู้เรียน ที่เปลี่ยนแปลงไปเรื่อย ๆ เมื่อผู้เรียนได้ตอบกับสื่อการเรียนรู้ การติดตามในลักษณะนี้ช่วยให้ระบบการศึกษาเข้าใจความสามารถของผู้เรียนรายบุคคลได้แม่นยำยิ่งขึ้น และสามารถนำไปสู่การออกแบบระบบการเรียนรู้แบบปรับตัว ที่ตอบสนองต่อความต้องการเฉพาะบุคคลได้ ซึ่งกระบวนการของ Knowledge Tracing โดยทั่วไปแล้วสามารถอธิบายได้เป็นลำดับขั้นตอนดังนี้

1. Data Collection (การเก็บข้อมูล) : บันทึกคำตอบ ผลลัพธ์ และเวลาที่ผู้เรียนใช้ตอบคำถาม
2. Modeling (การสร้างแบบจำลอง) : ประมวลผลข้อมูลด้วยโมเดลทางสถิติหรือโมเดลเชิงลึก เช่น Bayesian Knowledge Tracing (BKT) หรือ Deep Knowledge Tracing (DKT)
3. Prediction (การทำนาย) : โมเดลคาดการณ์ความน่าจะเป็นที่ผู้เรียนจะตอบถูกหรือผิดในคำถามถัดไป
4. Updating (การอัปเดตสถานะ) : ปรับปรุงค่าประมาณระดับความรู้ของผู้เรียนอย่างต่อเนื่องตามข้อมูลใหม่ที่ได้รับ

ซึ่งการนำ Knowledge Tracing มาใช้ในระบบ Learning Analytics สามารถประยุกต์ได้หลายรูปแบบ โดยโมเดลที่ใช้กันแพร่หลาย ได้แก่ Bayesian Knowledge Tracing (BKT) โดย Corbett และ Anderson ใช้โมเดลเครือข่ายเบย์ (Bayesian Network) เพื่อติดตามความน่าจะเป็นที่ผู้เรียนจะ รู้ หรือ ไม่รู้ ทักษะหนึ่ง ๆ

และอัปเดตค่าเมื่อผู้เรียนตอบคำถามใหม่ เหมาะกับระบบ e-learning ที่มีการวิเคราะห์เชิงสถิติ Deep Knowledge Tracing (DKT) โดย Piech จะเป็นการใช้โครงข่ายประสาทเทียมแบบ Recurrent Neural Network (RNN) เพื่อติดตามลำดับการเรียนรู้ของผู้เรียน สามารถจับความสัมพันธ์ที่ซับซ้อนในข้อมูลได้ดีกว่า BKT และแม่นยำกว่าในการทำนายพฤติกรรมการตอบในอนาคต

ในระบบแพลตฟอร์มการเรียนรู้ด้านคณิตศาสตร์ Knowledge Tracing สามารถนำมาใช้ในการประเมินว่าผู้เรียนเข้าใจหัวข้อใดแล้ว และควรได้รับโจทย์ระดับใดต่อไป เช่น หากระบบพบว่าผู้เรียนยังตอบผิดซ้ำในเรื่องอนุพันธ์ ระบบสามารถเลือกโจทย์ระดับพื้นฐานเพิ่ม หรือเสนอเนื้อหาอธิบายเพิ่มเติม ในขณะที่ผู้เรียนที่ผ่านโจทย์ระดับสูงได้แล้วอาจได้รับโจทย์เชิงวิเคราะห์ที่ซับซ้อนขึ้น

2.1.2 ทฤษฎีและเทคนิคด้านปัญญาประดิษฐ์และการเรียนรู้ของเครื่อง

2.1.2.1 Natural Language Processing (NLP)

Natural Language Processing (NLP) เป็นสาขาหนึ่งของปัญญาประดิษฐ์ หรือ AI และภาษาศาสตร์คอมพิวเตอร์ ที่มุ่งพัฒนาเทคนิคและอัลกอริทึมเพื่อให้คอมพิวเตอร์สามารถเข้าใจ ตีความ และสร้างภาษามนุษย์ได้อย่างมีประสิทธิภาพ ขอบเขตของ NLP ครอบคลุมการประมวลผลข้อความ (Text Processing) การทำความเข้าใจเชิงความหมาย (Semantic Understanding) และการสร้างภาษา (Natural Language Generation : NLG) ซึ่งมีบทบาทสำคัญในการพัฒนาระบบสนทนาอัตโนมัติ การสืบค้นข้อมูล ไปจนถึงการสร้างข้อสอบและเนื้อหาทางการศึกษาแบบอัตโนมัติ โดยหลักการทำงานของ NLP จะมีกระบวนการทำงานดังนี้

1. Text Input (การรับข้อความ) : รับข้อมูลภาษา เช่น คำถาม คำพูด หรือ โจทย์
2. Tokenization (การแบ่งหน่วยคำ) : แบ่งข้อความออกเป็นหน่วยย่อย เช่น คำหรือประโยค
3. Parsing (การวิเคราะห์โครงสร้าง) : วิเคราะห์โครงสร้างทางไวยากรณ์ ไม่ว่าจะเป็นความสัมพันธ์ระหว่างคำ หรือ บริบทของประโยค
4. Feature Extraction (การสกัดคุณลักษณะ) : แปลงข้อความให้อยู่ในรูปแบบตัวเลข เช่น Word Embeddings หรือ Contextual Embeddings จากโมเดลภาษาขนาดใหญ่
5. Classification / Generation (การจำแนกหรือการสร้างข้อความ) :
 - การจำแนก (Classification) เช่น วิเคราะห์ว่าคำตอบนักเรียนถูก/ผิด
 - การสร้าง (Generation) เช่น การสร้างโจทย์คณิตศาสตร์ใหม่
6. Output (ผลลัพธ์) : แสดงข้อความหรือคำตอบที่ระบบสร้างขึ้น

ทั้งนี้ในการประยุกต์ใช้ Natural Language Processing ในบริบทการศึกษา โดยเฉพาะในรายวิชาคณิตศาสตร์บทแคลคูลัสเบื้องต้น สามารถนำมาช่วยแก้ปัญหาที่พบในระบบการเรียนการสอนปัจจุบันได้อย่างมีประสิทธิภาพ ตัวอย่างการประยุกต์ใช้ ได้แก่

1. การสร้างโจทย์อัตโนมัติ

ระบบสามารถใช้เทคนิค NLP ในการสร้างข้อสอบใหม่จากคลังข้อสอบที่มีอยู่ โดยปรับรูปแบบคำถาม เนื้อหา และระดับความยากให้เหมาะสมกับผู้เรียนรายบุคคล ช่วยเพิ่มความหลากหลายของโจทย์ และทำให้ผู้เรียนได้ฝึกฝนในลักษณะที่ตรงกับความสามารถและความต้องการของตนเอง

2. การวิเคราะห์คำตอบ

NLP สามารถนำมาใช้ตรวจสอบความถูกต้องของคำตอบทั้งเชิงตัวเลขและคำอธิบายด้วยภาษาธรรมชาติ ระบบสามารถวิเคราะห์ว่าผู้เรียนมีการใช้เหตุผลที่ถูกต้องหรือไม่ แม้ว่าคำตอบสุดท้ายอาจไม่ถูกต้องก็ตาม อีกทั้งยังสามารถให้ข้อเสนอแนะอัตโนมัติ ที่ช่วยให้ผู้เรียนเข้าใจข้อผิดพลาดของตนเองได้

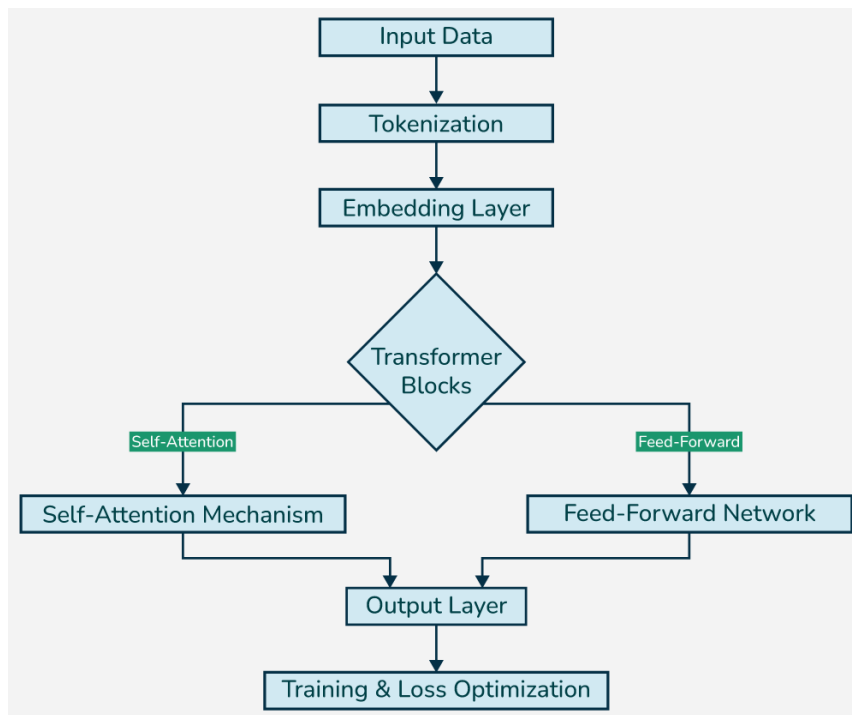
3. การสนับสนุน Personalized Learning

ด้วยการใช้ NLP ในการทำความเข้าใจพฤติกรรมคำตอบ ระบบสามารถปรับโจทย์และเนื้อหาให้เหมาะสมกับจุดแข็งและจุดอ่อนของผู้เรียนรายบุคคล ซึ่งช่วยแก้ปัญหาที่ผู้เรียนมักไม่รู้คำตอบอยู่ในระดับความเข้าใจใด และไม่สามารถประเมินพัฒนาการของตนเองได้อย่างชัดเจน

2.1.2.2 Large Language Models (LLMs)

Large Language Models (LLMs) คือโมเดลปัญญาประดิษฐ์ ประเภทหนึ่งที่ได้รับการพัฒนาให้สามารถประมวลผล สร้าง และทำความเข้าใจภาษามนุษย์ได้อย่างใกล้เคียงกับการสื่อสารตามธรรมชาติ โดยทั่วไป LLM จะถูกฝึกด้วยข้อมูลข้อความขนาดใหญ่จำนวนมากและใช้สถาปัตยกรรมโครงข่ายประสาทเชิงลึก โดยเฉพาะสถาปัตยกรรม Transformer ซึ่งมีความสามารถในการจับความสัมพันธ์ระหว่างคำในบริบทเดียวกันได้อย่างมีประสิทธิภาพ ตัวอย่างของ LLM ได้แก่ GPT, LLaMA, และ Claude ซึ่งถูกนำไปใช้ในหลายสาขา เช่น ระบบสนทนาอัตโนมัติ การสรุปข้อความ การสร้างโค้ด และการสร้างโจทย์อัตโนมัติทางการศึกษา ซึ่งกระบวนการทำงานของ LLM มีดังนี้

1. Pre-training : โมเดลถูกฝึกด้วยข้อความจำนวนมากเพื่อเรียนรู้รูปแบบทางสถิติของภาษา โดยใช้เทคนิค Self-Attention ของ Transformer
2. Embedding & Encoding : ข้อความถูกแปลงเป็นเวกเตอร์ (Embeddings) และเข้ารหัสด้วย Positional Encoding เพื่อรักษาลำดับข้อมูล
3. Attention Mechanism : โมเดลประเมินความสัมพันธ์ระหว่างโทเค็นแต่ละตัวเพื่อสร้างความเข้าใจบริบทที่ถูกต้อง
4. Fine-tuning / Instruction tuning : โมเดลถูกปรับให้เหมาะสมกับงานเฉพาะ เช่น การสร้างโจทย์คณิตศาสตร์หรือการตรวจคำตอบของผู้เรียน
5. Inference (การทำนายผล) : เมื่อผู้ใช้ป้อนข้อความ โมเดลจะสร้างผลลัพธ์ เช่น ข้อความใหม่ คำอธิบาย หรือโจทย์ที่ตรงตามระดับของผู้เรียน



ที่มา : <https://www.geeksforgeeks.org/artificial-intelligence/exploring-the-technical-architecture-behind-large-language-models>

สำหรับการประยุกต์ใช้ LLM สามารถนำมาประยุกต์ใช้ได้มากมาย ไม่ว่าจะเป็น การสร้างโจทย์คณิตศาสตร์ใหม่ที่มีความหลากหลายและปรับระดับความยากตาม Bloom's Taxonomy เพื่อให้ผู้เรียนได้ฝึกฝนอย่างเหมาะสม หรือจะเป็นการวิเคราะห์คำตอบของผู้เรียนโดยพิจารณาทั้งความถูกต้องเชิงตัวเลขและเหตุผลเชิงภาษาที่ใช้ พร้อมสร้าง feedback อัตโนมัติที่ช่วยชี้จุดอ่อนของผู้เรียน ด้วยความสามารถดังกล่าว LLM จึงถือเป็นเทคโนโลยีที่ช่วยเสริมประสิทธิภาพของแพลตฟอร์มการเรียนรู้ ทำให้เกิดการเรียนรู้แบบปรับเฉพาะบุคคลที่มีความแม่นยำและตอบโจทย์ความต้องการของผู้เรียนมากขึ้น

2.1.2.3 Automatic Question Generation (AQG)

Automatic Question Generation (AQG) คือกระบวนการสร้างข้อสอบหรือคำถามแบบอัตโนมัติจากข้อมูลที่มีอยู่ โดยอาศัยเทคนิคทางการประมวลผลภาษาธรรมชาติ (NLP) และการเรียนรู้ของเครื่อง (Machine Learning) AQG ได้รับความสนใจอย่างมากในด้านการศึกษา เนื่องจากสามารถสร้างโจทย์ที่มีคุณภาพและหลากหลายเพื่อช่วยผู้เรียนฝึกฝนได้อย่างมีประสิทธิภาพ

กระบวนการของ AQG เริ่มจากการเลือกหัวข้อหรือเนื้อหาที่ต้องการออกข้อสอบ จากนั้นระบบจะทำการวิเคราะห์ข้อความเชิงโครงสร้างและความหมายด้วยเทคนิค NLP ก่อนจะสร้างคำถามออกมาโดยใช้วิธี Rule-based หรือโมเดล Machine Learning ที่ซับซ้อน เช่น Deep Learning หรือ LLMs หลังจากนั้นจะมีการตรวจสอบความถูกต้อง ความชัดเจน และความเหมาะสมของโจทย์ ก่อนจัดเก็บลงในคลังข้อสอบเพื่อใช้งานต่อไป

ความสำคัญของ AQG อยู่ที่การช่วยลดภาระของครูผู้สอนในการสร้างข้อสอบจำนวนมาก อีกทั้งยังช่วยให้โจทย์มีความหลากหลายและปรับได้ตามระดับความยากที่เหมาะสมกับผู้เรียน การใช้ AQG ยังเปิดโอกาสให้ผู้เรียนสามารถเข้าถึงโจทย์ที่หลากหลายขึ้น ส่งผลต่อการเรียนรู้ที่ครอบคลุมและสมดุมากกว่าเดิม

การนำ AQG ไปใช้สามารถทำได้ทั้งแบบ Rule-based ที่อาศัยกฎเกณฑ์คณิตศาสตร์หรือโครงสร้างประโยค ไปจนถึงการใช้ Deep Learning และโมเดลภาษาอย่าง GPT-4 ที่สามารถสร้างโจทย์ได้หลายระดับความซับซ้อน รวมถึงการออกแบบโจทย์ที่สอดคล้องกับ Bloom's Taxonomy ตั้งแต่ระดับการจดจำ ความเข้าใจ ไปจนถึงการคิดเชิงวิเคราะห์และสร้างสรรค์

2.1.2.4 Machine Learning for Learner Analysis

Machine Learning (ML) คือสาขาหนึ่งของปัญญาประดิษฐ์ที่มุ่งเน้นการพัฒนาอัลกอริทึมและแบบจำลองเพื่อให้คอมพิวเตอร์สามารถเรียนรู้จากข้อมูลและทำนายผลลัพธ์ได้โดยไม่ต้องกำหนดกฎแบบตายตัว ในด้านการศึกษา ML ถูกนำมาใช้เพื่อวิเคราะห์ผู้เรียน โดยอาศัยข้อมูลที่เกิดขึ้นจากกระบวนการเรียนรู้ เช่น ผลการตอบข้อสอบ คะแนน และเวลาในการทำแบบทดสอบ เพื่อตรวจสอบรูปแบบการเรียนรู้และพัฒนาการของผู้เรียน ซึ่งกระบวนการใช้ Machine Learning ในการวิเคราะห์ผู้เรียนสามารถแบ่งออกเป็นลำดับขั้นดังนี้

1. Data Collection : การเก็บข้อมูลผู้เรียน เช่น ผลการตอบข้อสอบ คะแนน หรือพฤติกรรมการเรียนรู้
2. Preprocessing : การเตรียมข้อมูลให้อยู่ในรูปแบบที่เหมาะสม เช่น การจัดการข้อมูลที่ขาดหาย (missing values) และการปรับขนาดข้อมูล (normalization)
3. Model Training : การฝึกแบบจำลองด้วยข้อมูลผ่านการเตรียมแล้ว โดยอาจใช้เทคนิคการจำแนก (Classification) หรือการจัดกลุ่ม (Clustering)
4. Prediction : การนำแบบจำลองที่ได้มาใช้งานทำนายหรือจัดประเภทข้อมูลใหม่ของผู้เรียน
5. Reporting : การนำเสนอผลลัพธ์ในรูปแบบที่สามารถตีความได้ เช่น รายงานหรือแดชบอร์ด เพื่อช่วยให้ผู้เกี่ยวข้องเข้าใจข้อมูลเชิงลึก

การนำ Machine Learning มาใช้ใน Learner Analysis มีความสำคัญเนื่องจากช่วยให้สามารถทำความเข้าใจผู้เรียนได้อย่างเป็นระบบและมีหลักฐานเชิงข้อมูล การวิเคราะห์ด้วย ML สามารถเปิดเผยทั้งจุดแข็งและจุดที่ควรปรับปรุงของผู้เรียน รวมทั้งค้นหารูปแบบพฤติกรรมที่อาจไม่สามารถสังเกตได้ด้วยวิธีการทั่วไป นอกจากนี้ยังช่วยสนับสนุนการวิจัยด้านการศึกษาและการพัฒนานโยบายการเรียนการสอนที่สอดคล้องกับลักษณะของผู้เรียนมากยิ่งขึ้น

เทคนิคของ Machine Learning ที่ใช้ในการวิเคราะห์ผู้เรียนมีความหลากหลาย ขึ้นอยู่กับลักษณะข้อมูลและวัตถุประสงค์ของการศึกษา ตัวอย่างเช่น Logistic Regression และ Decision Tree มักถูกนำมาใช้สำหรับงานจำแนกประเภท (Classification) เพื่อระบุว่าผู้เรียนอยู่ในกลุ่มใด ขณะที่ K-Means Clustering มักใช้ในการจัดกลุ่ม (Clustering) เพื่อค้นหารูปแบบของผู้เรียนที่มีลักษณะใกล้เคียงกันวิธีการเหล่านี้ช่วยให้สามารถประมวลผลข้อมูลเชิงการเรียนรู้ได้อย่างมีประสิทธิภาพ และสร้างความเข้าใจเชิงลึกเกี่ยวกับผู้เรียนในมิติที่หลากหลาย

2.1.2.5 Statistical Analysis

การวิเคราะห์เชิงสถิติ (Statistical Analysis) คือกระบวนการวิเคราะห์ข้อมูลเชิงปริมาณโดยอาศัยหลักการและวิธีการทางสถิติ เพื่อสรุป อธิบาย ตีความ และใช้ข้อมูลในการตัดสินใจ จุดเริ่มต้นของการวิเคราะห์เชิงสถิติมีรากฐานจากวิชาคณิตศาสตร์สถิติ ซึ่งได้รับการพัฒนามายาวนานตั้งแต่คริสต์ศตวรรษที่ 18 โดยเริ่มจากการใช้เพื่อการเก็บข้อมูลประชากร (census) และการวิเคราะห์เชิงความน่าจะเป็น ก่อนจะขยายไปสู่การวิจัยทางสังคมศาสตร์ วิทยาศาสตร์ธรรมชาติ เศรษฐศาสตร์ ตลอดจนวิทยาการคอมพิวเตอร์ในปัจจุบัน วิธีการวิเคราะห์เชิงสถิติสามารถแบ่งออกได้เป็นสองระดับหลัก ได้แก่

1. สถิติเชิงพรรณนา (Descriptive Statistics) : ใช้สรุปข้อมูลให้อยู่ในรูปที่เข้าใจง่าย เช่น ค่าเฉลี่ย (mean) ค่ามัธยฐาน (median) ส่วนเบี่ยงเบนมาตรฐาน (standard deviation) และการแสดงผลในรูปแบบตารางหรือกราฟ
2. สถิติเชิงอนุมาน (Inferential Statistics) : ใช้ทดสอบสมมติฐานและทำการคาดการณ์จากข้อมูลตัวอย่างไปยังประชากร เช่น การทดสอบค่าเฉลี่ย (t-test), การวิเคราะห์ความแปรปรวน (ANOVA), การวิเคราะห์การถดถอย (Regression Analysis) และการทดสอบไคสแควร์ (Chi-square test)

โดยรายละเอียดของวิธีการทางสถิติ และแนวทางการประยุกต์ใช้งาน ได้ถูกสรุปไว้ในตารางนี้

วิธีการทางสถิติ	สิ่งที่แสดง/คำนวณได้	การประยุกต์ใช้งาน
ค่าเฉลี่ย (Mean)	ค่ากลางของข้อมูลทั้งหมด	ใช้สรุปผลการสอบเฉลี่ยของผู้เรียนในกลุ่มหนึ่ง
ค่ามัธยฐาน (Median)	ค่ากลางที่แท้จริงเมื่อเรียงข้อมูลตามลำดับ	ใช้วัดค่ากลางเมื่อข้อมูลมีค่าผิดปกติ (outlier)
ส่วนเบี่ยงเบนมาตรฐาน (SD)	ความกระจายของข้อมูลรอบค่าเฉลี่ย	ประเมินว่าผลการสอบของผู้เรียนมีความแตกต่างกันมากน้อยเพียงใด
การทดสอบค่าเฉลี่ย (t-test)	เปรียบเทียบค่าเฉลี่ยระหว่าง 2 กลุ่ม	ใช้ตรวจสอบว่าผลการเรียนของสองห้องเรียนแตกต่างกันหรือไม่
การวิเคราะห์ความแปรปรวน (ANOVA)	เปรียบเทียบค่าเฉลี่ยมากกว่า 2 กลุ่ม	ใช้เปรียบเทียบผลสัมฤทธิ์จากหลายวิธีการสอน
การถดถอยเชิงเส้น (Linear Regression)	ความสัมพันธ์ระหว่างตัวแปรอิสระกับตัวแปรตาม	ใช้คาดการณ์คะแนนสอบจากจำนวนชั่วโมงที่ผู้เรียนอ่านหนังสือ
การทดสอบไคสแควร์ (Chi-square)	ความสัมพันธ์ระหว่างตัวแปรเชิงคุณภาพ (categorical)	ใช้วิเคราะห์ความสัมพันธ์ระหว่างเพศกับผลการสอบผ่าน/ไม่ผ่าน

ซึ่งในงานด้านวิทยาการข้อมูลและการประยุกต์ใช้จริง การวิเคราะห์เชิงสถิติมักใช้ร่วมกับเครื่องมือทางโปรแกรมมิ่ง เช่น Pandas และ NumPy ในภาษา Python สำหรับการจัดการข้อมูล การคำนวณทาง

คณิตศาสตร์และสถิติ เช่น การหาค่าเฉลี่ย ร้อยละ ค่าสหสัมพันธ์ และการสร้างแบบจำลองทางสถิติ นอกจากนี้ยังนิยมใช้ Visualization Tools เช่น Matplotlib, Seaborn หรือ Plotly เพื่อสร้างการแสดงผลเชิงภาพ ในรูปแบบกราฟ แผนภูมิ และแดชบอร์ด ทำให้ผู้ใช้สามารถตีความข้อมูลได้ง่ายและรวดเร็ว

การนำเสนอข้อมูลด้วยแดชบอร์ดแบบโต้ตอบ ยังช่วยให้ผู้ใช้สามารถเลือกตัวชี้วัดหรือช่วงเวลาที่ต้องการศึกษาได้ ทำให้การวิเคราะห์เชิงสถิติไม่เพียงเป็นการคำนวณเชิงตัวเลข แต่ยังเป็นกระบวนการที่สนับสนุนการตัดสินใจและการวางแผนเชิงกลยุทธ์ได้อย่างมีประสิทธิภาพ

2.1.3 ทฤษฎีด้านการออกแบบระบบและซอฟต์แวร์

2.1.3.1 การพัฒนาเว็บแอปพลิเคชัน (Web Application Development)

การพัฒนาเว็บแอปพลิเคชัน (Web Application Development) คือกระบวนการสร้างระบบซอฟต์แวร์ที่ผู้ใช้สามารถเข้าถึงและใช้งานผ่านเว็บเบราว์เซอร์ได้ โดยไม่จำเป็นต้องติดตั้งโปรแกรมลงบนเครื่องคอมพิวเตอร์ของผู้ใช้ เว็บแอปพลิเคชันได้รับความนิยมอย่างแพร่หลาย เนื่องจากความสะดวกในการเข้าถึงรองรับการใช้งานบนหลายแพลตฟอร์ม และสามารถอัปเดตได้แบบเรียลไทม์

เว็บแอปพลิเคชันมักถูกพัฒนาบนสถาปัตยกรรมแบบ สามชั้น (Three-Tier Architecture) ได้แก่ ชั้นนำเสนอ (Presentation Layer), ชั้นการประมวลผล (Application Layer), และชั้นฐานข้อมูล (Data Layer) ซึ่งแต่ละชั้นมีหน้าที่แตกต่างกันและสามารถใช้เทคโนโลยีที่เหมาะสมในการพัฒนา

โดยรายละเอียดที่เกี่ยวกับองค์ประกอบหลักของเว็บแอปพลิเคชัน ได้ถูกสรุปไว้ในตารางนี้

องค์ประกอบ	คำอธิบาย	ตัวอย่างเทคโนโลยี
Frontend (Client Side)	ส่วนที่ผู้ใช้โต้ตอบโดยตรง เช่น หน้าตาเว็บไซต์ ปุ่มแบบฟอร์ม และการแสดงผลข้อมูล ใช้ภาษา HTML, CSS และ JavaScript เพื่อสร้างส่วนติดต่อผู้ใช้ และสามารถใช้ Framework/Library ช่วยเพิ่มประสิทธิภาพการพัฒนา	React.js, Vue.js, Angular, Tailwind CSS, Bootstrap
Backend (Server Side)	ส่วนที่ทำงานเบื้องหลัง เช่น การจัดการตรรกะของระบบ (Business Logic), การตรวจสอบสิทธิ์ผู้ใช้, และการสื่อสารกับฐานข้อมูล Backend มักให้บริการผ่าน API และทำงานร่วมกับ frontend อย่างต่อเนื่อง	FastAPI (Python), Node.js/Express, Django, Flask, Ruby on Rails, Spring Boot
Database	ส่วนจัดเก็บข้อมูลที่รองรับการเรียกใช้ของระบบ ข้อมูลอาจถูกเก็บในรูปแบบเชิงสัมพันธ์ (Relational Database) หรือไม่เชิงสัมพันธ์ (NoSQL Database) ขึ้นอยู่กับความเหมาะสมของระบบ	PostgreSQL, MySQL, Oracle (SQL); MongoDB, Firebase, Cassandra (NoSQL)
Web Server / Hosting	ทำหน้าที่ตอบสนองคำขอจากผู้ใช้และส่งข้อมูลกลับ เช่น HTML, CSS, JS หรือข้อมูลที่ผ่านการประมวลผลจาก Backend	Apache, Nginx, IIS, AWS (EC2, S3), Google Cloud, Microsoft Azure

API (Application Programming Interface)	ช่องทางที่ใช้ในการเชื่อมต่อข้อมูลระหว่าง frontend และ backend หรือเชื่อมต่อกับบริการอื่น ๆ เพื่อให้ระบบทำงานแบบบูรณาการ	REST API, GraphQL, gRPC
DevOps & Deployment	ส่วนที่ช่วยจัดการการพัฒนา การทดสอบ และการนำระบบขึ้นใช้งานจริง รวมถึงเครื่องมือสำหรับควบคุมเวอร์ชันและการ deploy	Docker, Kubernetes, Jenkins, GitHub Actions, GitLab CI/CD

2.1.3.2 การออกแบบแดชบอร์ดเพื่อการเรียนรู้ (Learning Dashboard Design)


การออกแบบแดชบอร์ดเพื่อการเรียนรู้ (Learning Dashboard Design) เป็นแนวทางในการจัดทำเครื่องมือสำหรับการนำเสนอข้อมูลเชิงการเรียนรู้ให้อยู่ในรูปแบบที่สามารถตีความได้ง่ายและชัดเจน แดชบอร์ดถูกพัฒนาขึ้นจากแนวคิดของ Learning Analytics และ Educational Data Mining ซึ่งมุ่งเน้นการประมวลผลข้อมูลเชิงพฤติกรรมและผลลัพธ์ทางการศึกษา แล้วถ่ายทอดออกมาในลักษณะภาพข้อมูล (Data Visualization) เพื่อสนับสนุนการตัดสินใจ การวิเคราะห์ และการติดตามพัฒนาการของผู้เรียน

การประยุกต์ใช้แดชบอร์ดในบริบททางการศึกษามีความสำคัญในหลายระดับ โดยในระดับผู้เรียน แดชบอร์ดช่วยให้สามารถติดตามความก้าวหน้า ระบุจุดแข็งและจุดที่ควรปรับปรุงของตนเองได้อย่างเป็นระบบ ในระดับผู้สอน แดชบอร์ดเป็นเครื่องมือในการประเมินและตรวจสอบผลการเรียนของผู้เรียนรายบุคคลและกลุ่ม เพื่อปรับปรุงกลยุทธ์การสอนให้เหมาะสมยิ่งขึ้น ส่วนในระดับผู้บริหาร แดชบอร์ดสามารถใช้ในการติดตามประสิทธิภาพของหลักสูตรและการเรียนการสอนในภาพรวม ทำให้การบริหารจัดการทางการศึกษามีความเป็นระบบและโปร่งใสมากขึ้น

การประยุกต์ใช้แดชบอร์ดมีความสำคัญอย่างยิ่ง เนื่องจากช่วยให้ผู้เรียนสามารถติดตามความก้าวหน้า และปรับปรุงตนเองได้ ผู้สอนสามารถใช้เพื่อติดตามผลการเรียนและปรับกลยุทธ์การสอน ขณะที่ผู้บริหารสามารถใช้เพื่อประเมินคุณภาพหลักสูตรและกระบวนการเรียนการสอนในภาพรวม การเลือกใช้วิธีการแสดงผลข้อมูลที่เหมาะสมจึงเป็นองค์ประกอบสำคัญในการทำให้แดชบอร์ดมีประสิทธิภาพและตอบสนองวัตถุประสงค์ของผู้ใช้งานได้อย่างแท้จริง

รูปแบบการแสดงผลที่นิยมใช้ในแดชบอร์ดเพื่อการเรียนรู้มีดังนี้


- Bar Chart (กราฟแท่ง)



ที่มา : https://commons.wikimedia.org/wiki/Category:Bar_charts

มีลักษณะเป็นแท่งแนวตั้งหรือแนวนอน ใช้แทนค่าของข้อมูลเพื่อเปรียบเทียบระหว่างหมวดหมู่ เช่น คะแนนเฉลี่ยรายวิชา เหมาะสำหรับการแสดงผลต่างของข้อมูลหลายหมวดหมู่ ทำให้เห็นความแตกต่างอย่างชัดเจน


- Line Chart (กราฟเส้น)



ที่มา : https://commons.wikimedia.org/wiki/Category:Line_charts

เป็นเส้นที่เชื่อมโยงค่าข้อมูลตามลำดับเวลา ใช้แสดงแนวโน้มการเปลี่ยนแปลง เช่น คะแนนสอบในแต่ละช่วงเวลา เหมาะสำหรับข้อมูลที่มีลักษณะอนุกรมเวลา (time series) และต้องการวิเคราะห์พัฒนาการหรือการเปลี่ยนแปลงในระยะยาว


- Radar Chart (กราฟใยแมงมุม)



ที่มา : https://commons.wikimedia.org/wiki/Category:Radar_charts

เป็นการแสดงผลข้อมูลหลายมิติในลักษณะรัศมีคล้ายใยแมงมุม ใช้เปรียบเทียบสมรรถนะหรือทักษะหลายด้านพร้อมกัน เช่น ทักษะการฟัง พูด อ่าน และเขียน เหมาะสำหรับการวิเคราะห์ความสมดุลและการเปรียบเทียบคุณลักษณะในหลายด้านของผู้เรียนในภาพรวมเดียว

- Heatmap (ฮีตแมพ)



ที่มา : https://commons.wikimedia.org/wiki/Category:Heat_maps

เป็นการใช้ระดับสีเข้ม-อ่อนแทนค่าความถี่ของข้อมูล เหมาะสำหรับการแสดงรูปแบบพฤติกรรม เช่น ความถี่ของการเข้าใช้งานระบบการเรียนรู้ตามช่วงเวลา ทำให้สามารถมองเห็นการกระจายตัวของข้อมูลเชิงพฤติกรรมได้อย่างชัดเจนในมิติของเวลาและกิจกรรม

2.1.4 ทฤษฎีด้านแคลคูลัสที่เกี่ยวข้อง

2.1.4.1 แคลคูลัสในระดับมัธยมปลาย

แคลคูลัสเป็นสาขาคณิตศาสตร์ที่ว่าด้วยการศึกษาอัตราการเปลี่ยนแปลงของปริมาณ (อนุพันธ์) และการหาพื้นที่ใต้กราฟ (ปริพันธ์) ซึ่งถือเป็นหัวใจสำคัญของคณิตศาสตร์เชิงวิเคราะห์ และเป็นรากฐานของศาสตร์แขนงต่าง ๆ เช่น วิทยาศาสตร์ วิศวกรรมศาสตร์ และเศรษฐศาสตร์ การจัดการเรียนการสอนแคลคูลัสในระดับมัธยมศึกษาตอนปลายมักเริ่มต้นจากการเรียนรู้เรื่องลิมิต อันเป็นพื้นฐานของการหาค่าอนุพันธ์ ก่อนจะต่อยอดไปสู่ปริพันธ์และการประยุกต์ใช้ในโจทย์ปัญหาต่าง ๆ เช่น การหาค่าที่เหมาะสมที่สุด การคำนวณพื้นที่หรือปริมาตร และการวิเคราะห์การเคลื่อนที่

อย่างไรก็ตาม แม้แคลคูลัสจะมีความสำคัญอย่างยิ่งต่อการศึกษาต่อในระดับอุดมศึกษา แต่ผู้เรียนจำนวนมากยังคงประสบความยากลำบากในการทำความเข้าใจหัวข้อนี้ ปัญหาที่พบบ่อย ได้แก่ ความซับซ้อนของสัญลักษณ์ทางคณิตศาสตร์ การตีความเชิงเรขาคณิตของอนุพันธ์และปริพันธ์ การอ่านและทำความเข้าใจกราฟ รวมถึงการเชื่อมโยงระหว่างสมการกับการประยุกต์ใช้จริง การเข้าใจถึงอุปสรรคเหล่านี้มีความสำคัญเนื่องจากช่วยให้ครูผู้สอนหรือระบบสนับสนุนการเรียนรู้สามารถออกแบบการสอนและสร้างเครื่องมือช่วยเหลือที่ตอบสนองต่อความต้องการที่แท้จริงของผู้เรียนได้อย่างมีประสิทธิภาพ

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 Clustering Analysis for Classifying Student Academic Performance in Higher Education (Nafuri A.F.M., Sani N.S., Zainudin N.F.A., Abd Rahman A.H., & Aliff M., 2022)

งานวิจัยนี้ศึกษาการใช้เทคนิค Clustering เพื่อจำแนกผลการเรียนของนักศึกษากลุ่มรายได้น้อยในมาเลเซีย (B40) จากข้อมูลกว่า 248,000 รายการ โดยวิเคราะห์ตัวแปรด้านผลการเรียน (CGPA), กิจกรรมนอกหลักสูตร, การฝึกงาน และสถานะการจ้างงาน วิธีการประกอบด้วยการทำความสะอาดข้อมูล การเลือกคุณลักษณะสำคัญ และการเปรียบเทียบอัลกอริธึม k-means, BIRCH และ DBSCAN ผลการทดลองพบว่า k-means ให้ผลดีที่สุด สามารถแบ่งนักศึกษาออกเป็น 5 กลุ่มที่สะท้อนความแตกต่างด้านการเรียนและปัจจัยสังคม ผลลัพธ์นี้มีคุณค่าต่อการระบุผู้เรียนที่เสี่ยงต่อการลาออกและช่วยกำหนดนโยบายเพิ่มอัตราการสำเร็จการศึกษา ทั้งยังชี้ว่าการใช้ Data Mining และ Machine Learning สามารถเป็นเครื่องมือสนับสนุนด้านการศึกษาที่มีประสิทธิภาพ แม้ยังมีข้อจำกัดเรื่องการครอบคลุมตัวแปรด้านจิตวิทยาหรือพฤติกรรมเชิงลึกของผู้เรียน

2.2.2 Automatic Question-Answer Pair Generation Using Pre-trained Large Language Models in Higher Education (Ling, Afzaal, et al., 2024)

งานวิจัยนี้มุ่งพัฒนาการสร้างคู่คำถาม-คำตอบโดยใช้โมเดลภาษาขนาดใหญ่ (LLMs) เพื่อสนับสนุนการเรียนรู้ในระดับอุดมศึกษา โดยเปรียบเทียบแนวทาง pipeline, joint และ multi-task learning ผ่านการปรับจูนโมเดล T5 และ BART บนชุดข้อมูลจากหลักสูตรจริง การประเมินใช้ทั้งตัวชี้วัดเชิงปริมาณ (BLEU, ROUGE,

METEOR) และการประเมินจากอาจารย์ผู้สอน ผลการทดลองพบว่า multi-task learning โดยเฉพาะโมเดล T5 ให้ผลลัพธ์ที่ดีที่สุด สร้างคำถาม-คำตอบที่มีคุณภาพและถูกต้องเหมาะสม อีกทั้งการทดลองในห้องเรียนจริงยังยืนยันว่ามีผลเชิงบวกต่อผลการเรียนของนักศึกษา งานนี้จึงสะท้อนศักยภาพของ LLMs ในการสนับสนุนการสร้างสื่อการสอนและการประเมินผล แม้ยังมีข้อจำกัดในด้านความยากของคำถามและความครอบคลุมของเนื้อหาเชิงลึก ซึ่งเปิดโอกาสให้วิจัยต่อยอดในอนาคต

2.2.3 Student Performance Prediction Using Machine Learning Algorithms (Ahmed et al., 2024)

งานวิจัยนี้เป็นการประยุกต์ใช้เทคนิคการเรียนรู้ของเครื่องเพื่อทำนายผลการเรียนของนักศึกษา โดยอาศัยข้อมูลด้านผลการเรียนและคุณลักษณะที่เกี่ยวข้องมาสร้างแบบจำลองเชิงทำนายเพื่อช่วยระบุผู้เรียนที่มีแนวโน้มจะประสบความสำเร็จหรือมีความเสี่ยงทางวิชาการ หลักการสำคัญคือการนำข้อมูลมาผ่านกระบวนการทำความสะอาดและเลือกคุณลักษณะที่สำคัญ จากนั้นจึงนำไปประยุกต์ใช้อัลกอริทึมจำแนกหลายรูปแบบ เช่น Support Vector Machine (SVM), Decision Tree, K-Nearest Neighbors (KNN) และ Naïve Bayes พร้อมทั้งทำการปรับแต่งพารามิเตอร์เพื่อเพิ่มประสิทธิภาพของแบบจำลอง ผลการทดลองพบว่า SVM ที่ผ่านการปรับแต่งพารามิเตอร์สามารถทำนายได้อย่างมีประสิทธิภาพสูงสุดด้วยความแม่นยำประมาณ 96% ในขณะที่ Naïve Bayes มีความแม่นยำน้อยที่สุดเนื่องจากข้อจำกัดด้านสมมติฐานการอิสระของตัวแปร ทั้งนี้ งานวิจัยสะท้อนให้เห็นว่าการใช้ Machine Learning สามารถช่วยเพิ่มศักยภาพในการติดตาม วิเคราะห์ และสนับสนุนการตัดสินใจในด้านการศึกษาได้อย่างมีประสิทธิภาพ

2.2.4 Updating Calculus Teaching with AI: A Classroom Experience (Torres-Peña et al., 2024)

งานวิจัยนี้มีวัตถุประสงค์เพื่อศึกษาการนำเทคโนโลยีปัญญาประดิษฐ์ หรือ AI เข้ามาประยุกต์ใช้ในการสอนรายวิชาแคลคูลัส ซึ่งเป็นรายวิชาที่มีความซับซ้อนและมักสร้างอุปสรรคต่อความเข้าใจของผู้เรียน วิธีการดำเนินการวิจัยคือการใช้เครื่องมือ AI หลายประเภท ได้แก่ ChatGPT, MathGPT, Gemini และ Wolfram Alpha ทำหน้าที่เสมือนผู้ช่วยสอนหรือผู้สอนเสมือนจริง ภายในห้องเรียน โดยให้นักศึกษาได้โต้ตอบ ซักถาม และรับคำอธิบายจาก AI เพื่อเสริมความเข้าใจในหัวข้อที่สอน ผลการศึกษาพบว่า AI มีบทบาทสำคัญในการช่วยให้นักศึกษาเข้าใจแนวคิดพื้นฐานของอัตราการเปลี่ยนแปลงและอนุพันธ์ได้ชัดเจนขึ้น อีกทั้งยังให้ข้อเสนอแนะในทันทีและสามารถอธิบายซ้ำได้ตามความต้องการ งานวิจัยนี้จึงยืนยันว่า AI สามารถเป็นกลไกสนับสนุนการเรียนการสอนที่ช่วยลดข้อจำกัดของวิธีการสอนแบบดั้งเดิม และเพิ่มประสิทธิภาพของการเรียนรู้ในรายวิชาคณิตศาสตร์ที่มีความซับซ้อนได้อย่างเป็นรูปธรรม

2.2.5 Automatic Question & Answer Generation Using Generative Large Language Model (Ehsan et al., 2025)

งานวิจัยนี้นำเสนอแนวทางการสร้างคำถามและคำตอบโดยอัตโนมัติจากข้อความ โดยใช้โมเดลภาษาขนาดใหญ่เชิงกำเนิด วิธีการดำเนินงานอาศัยเทคนิค extractive summarization ร่วมกับการวิเคราะห์คุณลักษณะของประโยค เพื่อระบุประโยคที่มีความสำคัญและเหมาะสมสำหรับการสร้างคำถามหรือคำตอบ จากนั้นจึงใช้การเรียนรู้แบบมีผู้สอน (supervised learning) เพื่อฝึกโมเดลให้สามารถสร้างผลลัพธ์ที่สอดคล้อง

และมีคุณภาพ การประเมินผลใช้ตัวชี้วัดมาตรฐาน ได้แก่ ROUGE-2 และ ROUGE-L เพื่อตรวจสอบความใกล้เคียงกับข้อความที่มนุษย์สร้างขึ้น ผลการทดลองชี้ว่าโมเดลที่พัฒนามีประสิทธิภาพสูงในการสร้างสื่อการเรียนรู้ ทั้งในด้านความถูกต้อง ความเชื่อมโยง และความเหมาะสมเชิงการศึกษา งานวิจัยนี้แสดงให้เห็นถึงศักยภาพของ LLM ในการเป็นเครื่องมือสนับสนุนการจัดทำสื่อการเรียนรู้ที่ช่วยลดภาระครูผู้สอน และเพิ่มโอกาสให้ผู้เรียนได้รับการฝึกฝนและการประเมินที่มีคุณภาพอย่างต่อเนื่อง

2.2.6 Student Performance Analytics - Logic Research Labs

ระบบ *Student Performance Analytics* ที่พัฒนาโดย Logic Research Labs เป็นซอฟต์แวร์ที่ออกแบบมาเพื่อช่วยสถาบันการศึกษาในการติดตามและวิเคราะห์ผลการเรียนรู้ของนักเรียนอย่างเป็นระบบ จุดมุ่งหมายหลักของระบบคือการสนับสนุนการตัดสินใจของครูและผู้บริหารสถานศึกษา โดยอาศัยข้อมูลเชิงลึกเพื่อระบุจุดแข็งและจุดอ่อนของผู้เรียน รวมถึงสร้างแนวทางการเรียนรู้ที่เหมาะสมกับแต่ละบุคคล ระบบประกอบด้วยฟังก์ชันสำคัญ เช่น การวิเคราะห์ผลการสอบในรายวิชาและชั้นเรียน การสร้างแดชบอร์ดเชิงภาพเพื่อให้เห็นแนวโน้มของผลการเรียนอย่างชัดเจน ตลอดจนความสามารถในการจำแนกนักเรียนที่มีผลการเรียนต่ำ นักเรียนที่อยู่ในเกณฑ์เสี่ยง หรือผู้เรียนที่มีพัฒนาการช้า นอกจากนี้ยังสามารถวิเคราะห์กิจกรรมนอกหลักสูตรและทักษะด้านการฟัง พูด อ่าน เขียน (LSRW) ได้อีกด้วย ระบบดังกล่าวยังรองรับการนำเข้าข้อมูลการตรวจสอบความถูกต้องของผลคะแนน และการส่งออกรายงานในรูปแบบไฟล์มาตรฐาน เพื่อให้ครูและผู้บริหารสามารถใช้ข้อมูลได้สะดวกและมีประสิทธิภาพ

ประโยชน์สำคัญของ *Student Performance Analytics* คือการช่วยให้ครูและสถาบันสามารถดำเนินการสอนอย่างมุ่งเน้นผู้เรียน (learner-centered) ได้มากขึ้น เนื่องจากสามารถใช้ข้อมูลเชิงวิเคราะห์ในการปรับกลยุทธ์การสอนและออกแบบกิจกรรมการเรียนรู้ที่เหมาะสมกับผู้เรียนแต่ละกลุ่ม อีกทั้งยังช่วยให้นักเรียนเห็นพัฒนาการของตนเองและได้รับแรงจูงใจในการพัฒนาผลการเรียนต่อไป ระบบนี้จึงถือเป็นเครื่องมือสำคัญที่ช่วยยกระดับคุณภาพการศึกษาและสนับสนุนการตัดสินใจเชิงนโยบายภายในสถานศึกษา

เพื่อให้เห็นความแตกต่างอย่างชัดเจนระหว่างระบบที่มีอยู่และแพลตฟอร์มที่ผู้วิจัยพัฒนาขึ้น จึงได้จัดทำตารางเปรียบเทียบฟีเจอร์และขอบเขตการทำงานของทั้งสองระบบ ดังแสดงในตารางต่อไปนี้

ฟีเจอร์ / ความสามารถ	แพลตฟอร์มที่พัฒนา	Student Performance Analytics
การสร้างข้อสอบอัตโนมัติ	มี (สร้างจากคลัง มีระดับความยาก)	ไม่มี
การปรับเนื้อหาให้เหมาะกับ ผู้เรียน (Personalized Learning)	มี (วิเคราะห์จุดแข็ง-จุดอ่อน รายบุคคล)	มีเฉพาะการวิเคราะห์รวม ไม่เจาะ รายบุคคล
การวิเคราะห์ผลการทำ ข้อสอบ	วิเคราะห์เชิงลึก พร้อมชี้ข้อผิดพลาด และคำแนะนำ	วิเคราะห์เชิงสถิติ เช่น เฉลี่ย กระจายตัว
แดชบอร์ดสรุปผล	แสดงพัฒนาการรายบุคคล	Analytical dashboard สำหรับผลรวม ของห้อง/วิชา
การระบุผู้เรียนที่มีปัญหา	ชี้จุดอ่อนรายบุคคล หัวข้อที่ทำผิดซ้ำ	ระบุกลุ่มนักเรียนอ่อน/เสี่ยง (slow learners)
การครอบคลุมเนื้อหา/วิชา	เฉพาะคณิตศาสตร์ ม.ปลาย (แคลคูลัส)	ทุกวิชาและหลายระดับการศึกษา
ผู้ใช้หลัก	นักเรียนและครู (ติดตามรายบุคคล)	ครูและผู้บริหาร (ติดตามภาพรวม)

และจากการทบทวนงานวิจัยที่เกี่ยวข้องทั้งหมด สามารถสรุปประเด็นที่มีความสอดคล้องและความแตกต่างเมื่อเปรียบเทียบกับโครงการที่พัฒนาขึ้นได้ดังนี้

งานวิจัยที่เกี่ยวข้อง	สาระสำคัญของงาน	จุดที่เหมือนกัน	จุดที่แตกต่างกัน
Nafuri et al. (2022) – Clustering Analysis for Classifying Student Academic Performance	ใช้เทคนิค Clustering เพื่อ จำแนกผลการเรียนของ นักศึกษากลุ่ม B40 ในมาเลเซีย จากข้อมูลกว่า 248,000 รายการ พบว่า k-means ให้ ผลดีที่สุด แบ่งนักศึกษาได้ 5 กลุ่ม	การใช้ Machine Learning เพื่อ วิเคราะห์และจัด กลุ่มผู้เรียนตาม ข้อมูลและ พฤติกรรม	งานวิจัยนี้เน้นข้อมูลเชิง สังคมและผลการเรียน (CGPA, การจ้างงาน ฯลฯ) ส่วนโปรเจกต์ของเราเน้น พฤติกรรมการทำข้อสอบ แคลคูลัส และการสะท้อน ผลรายบุคคล
Ling et al. (2024) – Automatic	ศึกษาการสร้างคู่คำถาม- คำตอบด้วย LLMs (T5, BART)	การใช้ LLMs สนับสนุนการ	งานนี้เน้นการสร้าง คำถาม- คำตอบทั่วไป

Question-Answer Pair Generation Using Pre-trained LLMs	เปรียบเทียบ pipeline, joint, multi-task learning พบว่า multi-task learning โดย T5 ให้ผลดีที่สุดและมีผลบวกต่อการเรียนจริง	สร้างโจทย์/คำถามเพื่อใช้ในการเรียนการสอน	ระดับอุดมศึกษา ส่วนโปรเจกต์ของเรามุ่งที่ ข้อสอบแคลคูลัส ม.ปลาย พร้อมการปรับระดับความยาก
Ahmed et al. (2024) – Student Performance Prediction Using Machine Learning Algorithms	ใช้ ML ทำนายผลสัมฤทธิ์ทางการเรียนจากคุณลักษณะต่างๆและผลการเรียน พบว่า SVM มีประสิทธิภาพและแม่นยำสูงสุด	การใช้ Machine Learning เพื่อทำนายและวิเคราะห์ผลการเรียนของผู้เรียน	งานวิจัยนี้เน้นการทำนายการเรียนจากคุณลักษณะต่างๆส่วนโปรเจกต์ของเราเน้น วิเคราะห์พฤติกรรมจากการทำข้อสอบจริง เพื่อสะท้อนจุดแข็ง-จุดอ่อน
Torres-Peña et al. (2024) – Updating Calculus Teaching with AI	ทดลองใช้ AI ในการสอน แคลคูลัส พบว่าช่วยให้นักเรียนเข้าใจแนวคิดอัตราการเปลี่ยนแปลงและอนุพันธ์ได้ชัดเจนขึ้น	มีการใช้ AI สนับสนุนการเรียนการสอน แคลคูลัสโดยตรง	งานนี้เน้น AI เป็น ผู้ช่วยสอน ในห้องเรียนจริง ส่วนโปรเจกต์ของเราเป็นการนำ AI มาช่วยในระบบการสร้างข้อสอบ
Ehsan et al. (2025) – Automatic Q&A Generation Using Generative LLM	ใช้ LLM แบบ Generative สร้างคำถาม-คำตอบจากข้อความ ร่วมกับ extractive summarization และ supervised learning เพื่อสร้างสื่อการเรียนรู้คุณภาพ	การใช้ LLM เพื่อสร้างสื่อการเรียนรู้/ข้อสอบอัตโนมัติ	งานนี้เน้น การสกัดข้อความทั่วไปเพื่อสร้าง Q&A ส่วนโปรเจกต์ของเราโฟกัสที่ โจทย์แคลคูลัสและการปรับระดับความยากให้เหมาะกับผู้เรียน
Logic Research Labs – Student Performance Analytics	ระบบซอฟต์แวร์วิเคราะห์ผลการเรียนและพฤติกรรมผู้เรียน สร้างแดชบอร์ด วิเคราะห์จุดแข็ง-อ่อน และระบุผู้เรียนที่มีความเสี่ยง	การวิเคราะห์ผลการเรียนและใช้แดชบอร์ดแสดงผล	ซอฟต์แวร์นี้ครอบคลุมทุกวิชาและเน้นสนับสนุนครู ในขณะที่โปรเจกต์ของเราเน้นเฉพาะแคลคูลัส ม.ปลายและให้Feedbackเชิงลึกเป็นรายบุคคล จากการทำข้อสอบ

บทที่ 3

วิธีการทำงาน กระบวนการและการออกแบบ

บทนี้นำเสนอระเบียบวิธีและขั้นตอนการพัฒนาเว็บไซต์เพื่อการสร้างข้อสอบและการวิเคราะห์ผลการเรียนรู้ของผู้เรียน โดยมีวัตถุประสงค์เพื่ออธิบายแนวทางการพัฒนา สถาปัตยกรรมระบบ เครื่องมือและเทคโนโลยีที่ใช้ ฟังก์ชันการทำงาน ตลอดจนการออกแบบส่วนติดต่อผู้ใช้ ซึ่งเป็นองค์ประกอบสำคัญที่ทำให้ผู้ใช้งานสามารถเข้าถึงฟังก์ชันของระบบได้อย่างมีประสิทธิภาพ

3.1 ภาพรวมของระบบและฟีเจอร์หลัก

ระบบที่พัฒนาขึ้นนี้มีจุดประสงค์เพื่อเป็นเครื่องมือสนับสนุนการเรียนรู้คณิตศาสตร์ โดยเฉพาะหัวข้อแคลคูลัสระดับมัธยมปลาย ซึ่งมักเป็นปัญหาสำหรับผู้เรียนจำนวนมาก ระบบถูกออกแบบให้สามารถสร้างข้อสอบที่เหมาะสมกับระดับความสามารถของผู้เรียน วิเคราะห์ผลการทำข้อสอบอย่างละเอียด และสะท้อนพัฒนาการในรูปแบบที่เข้าใจง่าย จุดเด่นของระบบคือการนำเทคโนโลยีการวิเคราะห์ข้อมูลมาผสมผสานกับกระบวนการเรียนรู้ นำเสนอในรูปแบบที่เข้าใจง่าย เพื่อให้ผู้เรียนได้รับประสบการณ์ที่เป็นรายบุคคล และผู้เรียนสามารถใช้ข้อมูลเหล่านี้ในการปรับปรุงกระบวนการเรียนของตนเองได้อย่างเหมาะสม โดยระบบสามารถแบ่งออกเป็นฟีเจอร์หลักดังต่อไปนี้

1. สร้างข้อสอบใหม่จากคลังข้อสอบที่มีอยู่ โดยสามารถปรับระดับความยากง่ายให้เหมาะสมกับผู้เรียน

ระบบจะทำการสร้างข้อสอบใหม่โดยอ้างอิงจากคลังข้อสอบที่มีอยู่ โดยเน้นการเลือกโจทย์ให้สอดคล้องกับหัวข้อและระดับความยากที่เหมาะสมกับผู้เรียนในแต่ละกลุ่ม ความสามารถในการปรับความยากง่ายของโจทย์ช่วยให้ผู้เรียนสามารถฝึกทำข้อสอบได้ตรงกับระดับความเข้าใจของตนเองและสอดคล้องกับหัวข้อที่ตนเองอยากพัฒนา

2. วิเคราะห์คำตอบของผู้เรียนเพื่อสะท้อนจุดแข็งและจุดอ่อน พร้อมแสดงข้อผิดพลาดที่มักเกิดขึ้น

ระบบออกแบบมาเพื่อวิเคราะห์ผลการทำข้อสอบของผู้เรียนในเชิงลึก โดยไม่เพียงแค่ตรวจคำตอบว่าถูกหรือผิด แต่ยังสามารถสะท้อนให้ผู้เรียนเห็นจุดแข็งและจุดอ่อนของตนเองจากสถิติการทำข้อสอบ รวมถึงชี้ให้เห็นข้อผิดพลาดที่มักเกิดขึ้นบ่อย การวิเคราะห์เช่นนี้จะช่วยให้ผู้เรียนเข้าใจปัญหาของตนเองได้อย่างตรงจุด และสามารถนำข้อมูลไปใช้ในการปรับปรุงการเรียนรู้ได้อย่างมีประสิทธิภาพ

3. สามารถแสดงพัฒนาการของผู้เรียนในรูปแบบที่เข้าใจง่าย

ระบบจะนำเสนอพัฒนาการของผู้เรียนในรูปแบบที่เข้าใจง่าย ทำการจัดเก็บผลการทำข้อสอบในแต่ละครั้ง และแสดงออกมาเป็นข้อมูลเชิงภาพ เช่น กราฟหรือแผนภูมิ เพื่อให้ผู้เรียนสามารถมองเห็นความก้าวหน้าในการเรียนรู้ของตนเองได้อย่างชัดเจน และเปิดโอกาสให้มีการเปรียบเทียบผลลัพธ์ทั้งในเชิงเวลาและระหว่างกลุ่มผู้เรียน ข้อมูลเช่นนี้จะช่วยให้ผู้เรียนและผู้สอนเข้าใจทิศทางการเรียนรู้ได้ชัดเจนขึ้น มองเห็นจุดที่พัฒนาแล้ว และจุดที่ยังต้องเสริมเพิ่มเติม ส่งผลให้กระบวนการเรียนรู้เกิดความต่อเนื่องและมีประสิทธิภาพสูงสุด

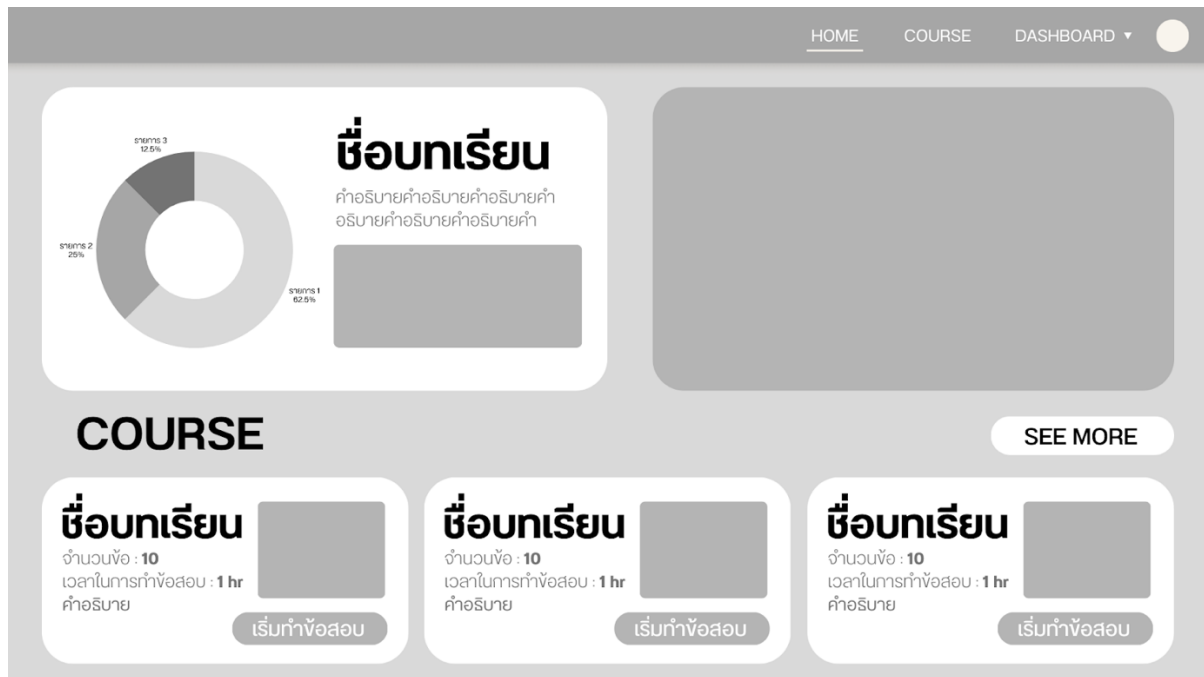
3.2 การออกแบบระบบ (System Design)

3.2.1 การออกแบบส่วนติดต่อผู้ใช้ (User Interface Design)

เพื่อให้ผู้ใช้สามารถใช้งานระบบได้ง่ายและสะดวก มีการออกแบบ UI ในลักษณะ Wireframe/Mockup โดยเน้นความเรียบง่าย ชัดเจน และครอบคลุมการใช้งานหลักทั้งหมด ดังนี้

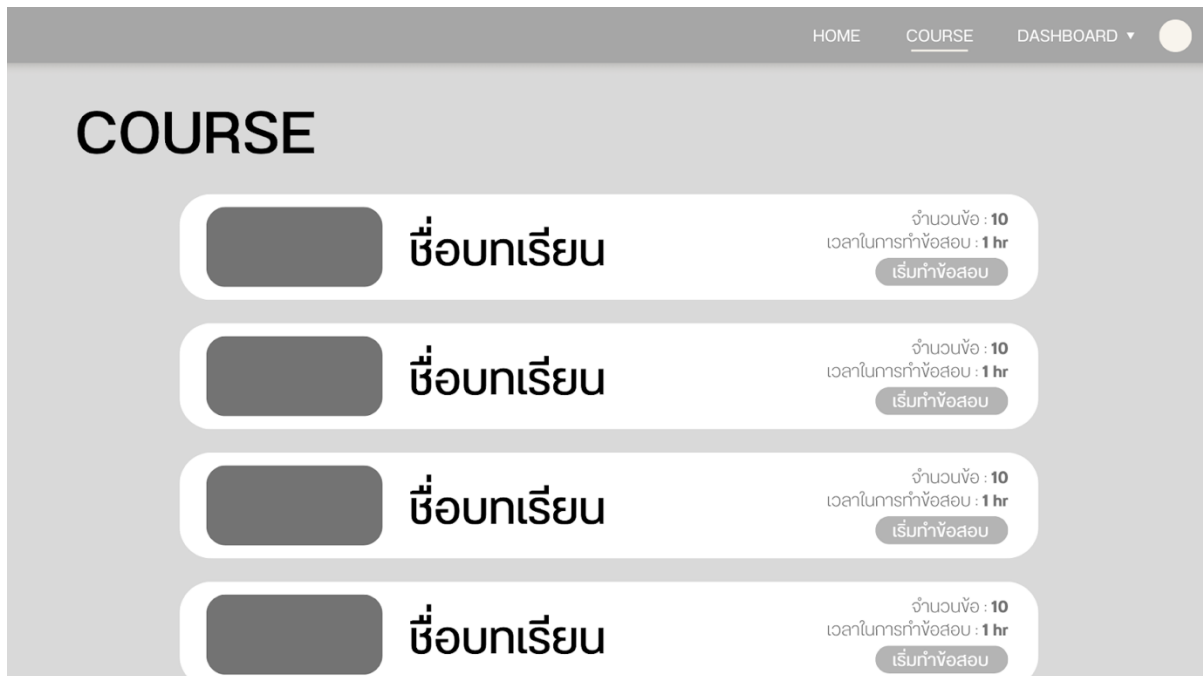
1. หน้า Home

- แสดงสรุปภาพรวมของบทเรียนและข้อสอบที่เปิดให้ทำ
- มีพื้นที่สำหรับสถิติเบื้องต้น เช่น กราฟสรุปผลการทำข้อสอบ



2. หน้า Course

- แสดงรายการบทเรียนทั้งหมดที่มีข้อสอบ
- แต่ละบทเรียนมีรายละเอียด เช่น จำนวนข้อสอบ เวลาที่ใช้ทำ
- ผู้เรียนสามารถกด “เริ่มทำข้อสอบ” เพื่อเข้าสู่การทำแบบทดสอบ



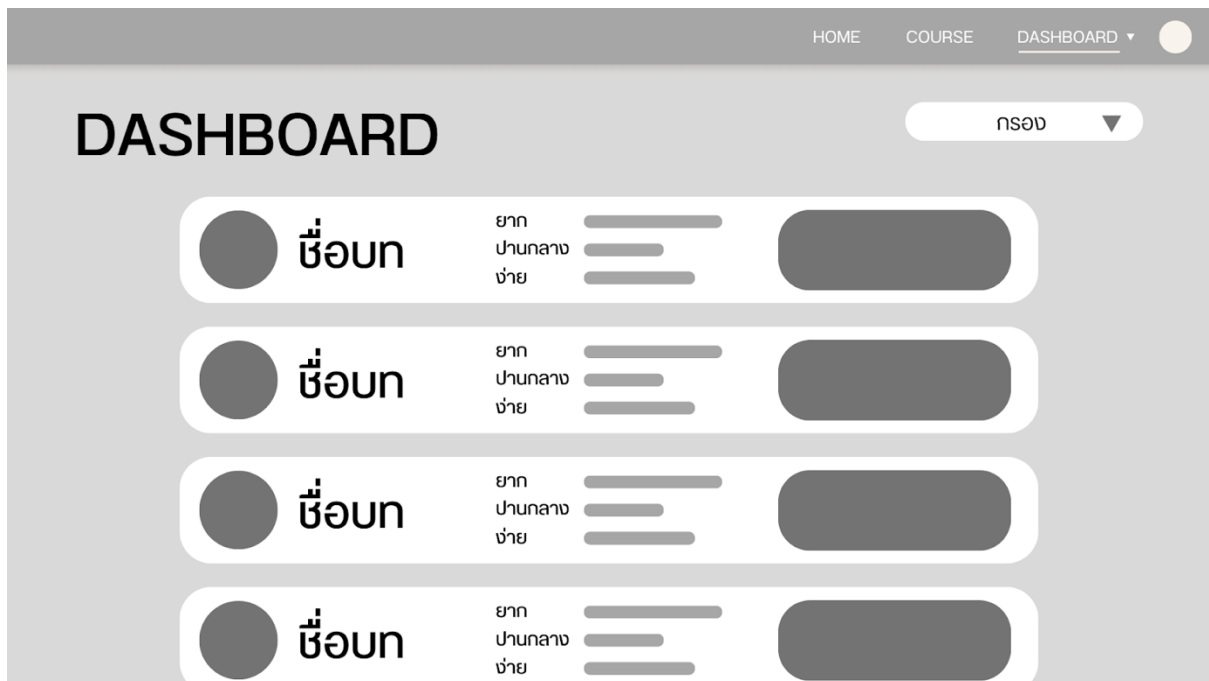
3. หน้าทำข้อสอบ (Exam Page)

- แสดงคำถามแบบปรนัยพร้อมตัวเลือก
- มีตัวจับเวลา และปุ่มสำหรับเปลี่ยนข้อก่อนหน้า/ถัดไป
- เมื่อทำครบ สามารถกด “Submit” เพื่อส่งคำตอบ



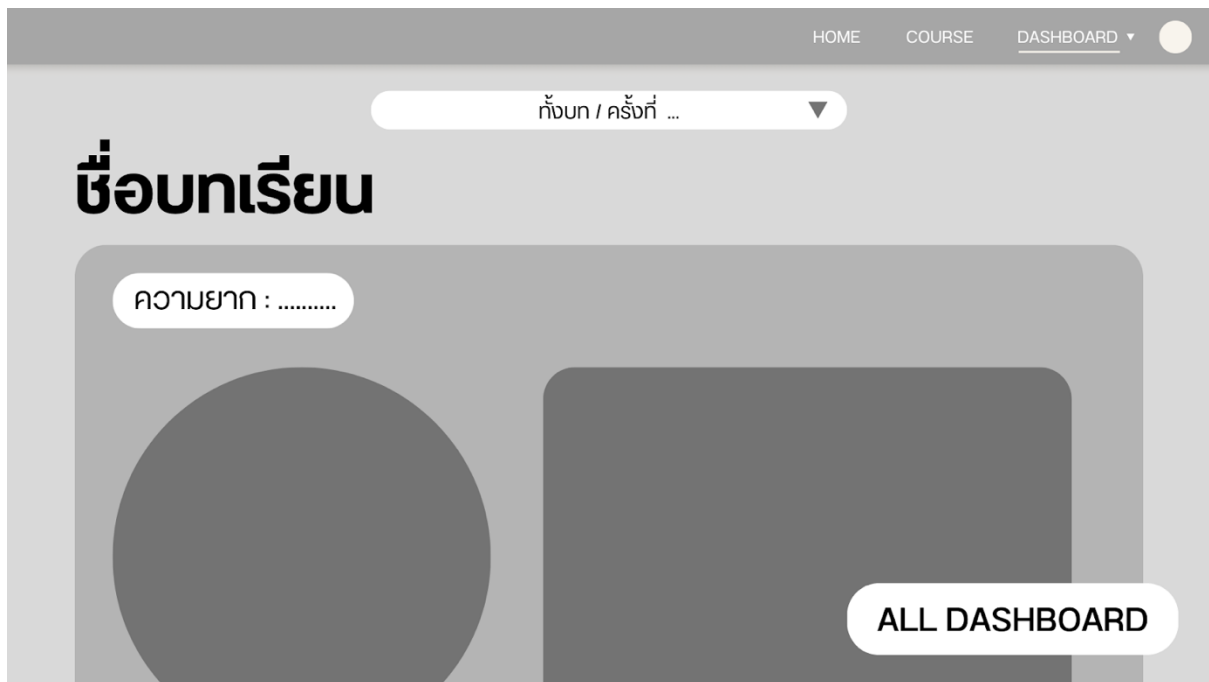
4. หน้า Dashboard (ภาพรวม)

- แสดงผลการทำข้อสอบของผู้เรียนในแต่ละบท
- ใช้แถบหรือกราฟแสดงจำนวนข้อที่ทำถูกในระดับง่าย-ปานกลาง-ยาก



5. หน้า Dashboard รายบท

- แสดงผลการทำข้อสอบในแต่ละบทเรียนเชิงลึก
- มีการแสดงค่าความยากและผลคะแนนด้วยกราฟในรูปแบบต่างๆ รวมไปถึงคำอธิบาย



อ้างอิง

1. Ahmed, E., et al. (2024). Student performance prediction using machine learning algorithms. *Applied Computational Intelligence and Soft Computing*, 2024, Article 4067721. <https://doi.org/10.1155/2024/4067721>
2. Anderson, L. W., & Krathwohl, D. R. (Eds.). (2001). *A taxonomy for learning, teaching, and assessing: A revision of Bloom's taxonomy of educational objectives*. New York: Longman.
3. Bloom, B. S. (1956). *Taxonomy of educational objectives: The classification of educational goals. Handbook I: Cognitive domain*. New York: McKay.
4. Corbett, A. T., & Anderson, J. R. (1994). Knowledge tracing: Modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4(4), 253–278.
5. Ehsan, M. A., et al. (2025). Automatic question & answer generation using generative large language model. *arXiv preprint arXiv:2508.19475*. <https://arxiv.org/abs/2508.19475>
6. GeeksforGeeks. (2025, August 6). Natural language processing (NLP) – Overview. Retrieved September 19, 2025, from <https://www.geeksforgeeks.org/nlp/natural-language-processing-overview/>
7. GeeksforGeeks. (2025a). What is a large language model (LLM). Retrieved September 19, 2025, from <https://www.geeksforgeeks.org/artificial-intelligence/large-language-model-llm/>
8. GeeksforGeeks. (2025c). Exploring the technical architecture behind large language models. Retrieved September 19, 2025, from <https://www.geeksforgeeks.org/artificial-intelligence/exploring-the-technical-architecture-behind-large-language-models/>
9. GeeksforGeeks. (n.d.). Web application architecture – Types, layers, and components. Retrieved September 19, 2025, from <https://www.geeksforgeeks.org>
10. Justinmind. (n.d.). Dashboard design: Best practices and examples. Retrieved September 19, 2025, from <https://justinmind.com>
11. Jurafsky, D., & Martin, J. H. (2023). *Speech and language processing* (3rd ed., draft). Stanford University.
12. Kurdi, G., Leo, J., Parsia, B., Sattler, U., & Al-Emari, S. (2020). A systematic review of automatic question generation for educational purposes. *International Journal of Artificial Intelligence in Education*, 30(1), 121–204.

13. Ling, J., Afzaal, M., et al. (2024). Automatic question–answer pairs generation using pre-trained large language models in higher education. *Computers & Education: Artificial Intelligence*, 6, 100252. <https://doi.org/10.1016/j.caeai.2024.100252>
14. Logic Research Labs. (n.d.). Student performance analytics (iSuccess). Retrieved September 21, 2025, from <https://logicresearchlabs.com/student-performance-analytics/>
15. Nafuri, A. F. M., Sani, N. S., Zainudin, N. F. A., Abd Rahman, A. H., & Aliff, M. (2022). Clustering analysis for classifying student academic performance in higher education. *Applied Sciences*, 12(19), 9467. <https://doi.org/10.3390/app12199467>
16. Orton, A. (1983). Students' understanding of differentiation. *Educational Studies in Mathematics*, 14(3), 235–250.
17. Piech, C., Bassen, J., Huang, J., Ganguli, S., Sahami, M., Guibas, L., & Sohl-Dickstein, J. (2015). Deep knowledge tracing. In *Advances in neural information processing systems* (Vol. 28, pp. 505–513).
18. ScopicSoftware. (n.d.). Web application architecture: Types, components & best practices. Retrieved September 19, 2025, from <https://scopicsoftware.com>
19. Sedraky, G., et al. (2019). Guiding the choice of learning dashboard visualizations. *Computers in Human Behavior*. Elsevier.
20. Sisense. (n.d.). 4 dashboard design principles for better data visualization. Retrieved September 19, 2025, from <https://sisense.com>
21. Stewart, J. (2015). *Calculus: Early transcendentals* (8th ed.). Boston: Cengage Learning.
22. Tall, D. (1993). Students' difficulties in calculus. In *Proceedings of Working Group 3 on Students' Difficulties in Calculus*, ICME-7.
23. Torres-Peña, R. C., Peña-González, D., Chacuto-López, E., Ariza, E. A., & Vergara, D. (2024). Updating calculus teaching with AI: A classroom experience. *Education Sciences*, 14(9), 1019. <https://doi.org/10.3390/educsci14091019>
24. Wang, Y., & Beck, J. E. (2017). Theoretical and empirical analysis of BKT and DKT. In *Proceedings of the 10th International Conference on Educational Data Mining* (pp. 139–146).
25. Wikimedia Commons. (n.d.). ภาพประกอบ Bar, Line, Radar, Gauge, Heatmap charts. Retrieved September 19, 2025, from <https://commons.wikimedia.org>
26. Zandieh, M. (2000). A theoretical framework for analyzing student understanding of the concept of derivative. *CBMS Issues in Mathematics Education*, 8, 103–122.